

分类号_____

密级_____

U D C_____

编号_____

硕士学位论文

题目：基于注意力机制与图神经网络
的交通流量预测

学位申请人姓名：_____

申请学位学生类别：应用统计硕士

申请学位学科专业：应用统计

指导教师姓名：_____

硕士学位论文

论文题目：基于注意力机制与图神经网络的交通流量预测

论文作者：

指导教师：

学科专业：应用统计

研究方向：应用统计

2025 年 5 月

Traffic Flow Prediction Based on Attention Mechanism and Graph Neural Networks

A Thesis

Submitted in Partial Fulfillment of the Requirement

For the M.S. Degree in Applied Statistics

By

Postgraduate Program

Supervisor:

Academic Title:

Signature_____

Approved

May 2025

XXXXXX学位论文原创性声明和使用授权说明

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

作者签名：

日期： 年 月 日

学位论文版权使用授权书

学位论文作者完全了解 XXXXXX 有关保留、使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属 XXXXXX。学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。（保密的学位论文在解密后遵守此规定）

保密论文严格按照《XXXXXX 涉密研究生与涉密学位论文管理办法》进行管理。非保密论文不属于保密范围，适用本授权书。

因特殊情况需延期发布的论文，同意论文提交后延期 ☐ 半年；☐ 一年；☐ 二年发布。到期后适用本授权书。

作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

交通流量预测是智能交通系统中的核心任务之一，能够为交通管理和城市规划提供关键的决策支持。然而，随着城市的不断发展，交通网络日益复杂，规模呈指数级增长，传统的交通流量预测方法面临着许多新的挑战。主要集中在下述方面：(1) 交通流量具有强烈的时空依赖性，如何进行时空关联捕获；(2) 如何进行多源异质数据融合；(3) 如何解决计算复杂度过高的问题等。

为了应对这些挑战，本研究创新性地提出了一种基于时空注意力机制和自适应图卷积网络的联合模型。

时空注意力机制能够自适应地学习时间和空间上的重要特征，帮助模型聚焦于影响交通流量的关键时段和关键区域。其中，时间注意力机制通过为不同时间步的输入赋予不同权重，使模型能够关注交通流量波动较大的时间段，这一机制能显著增强模型捕捉非线性趋势和长期依赖关系的能力。与此同时，空间注意力机制的引入，有效缓解了图卷积的过平滑问题。该机制通过动态调整每个节点与其邻居节点之间的相互影响，空间注意力机制能够避免信息的过度平均化，增强模型对局部特征的敏感性，从而提升预测精度。

其次，在图卷积网络的优化方面，本研究采用了自适应图网络技术，使模型能够学习并反映节点间复杂的潜在关系。这一改进不仅简化了计算流程，而且在处理大规模交通网络数据时显著降低了计算成本，避免了内存溢出和长时间运行的问题，从而提升了模型的实用性。

此外，本研究还在模型中尝试了多源信息的融合，将外部相关数据（如天气条件、POI 信息等）纳入考虑。这一举措进一步提升了模型的预测精度，证明了多信息融合在交通流量预测中的有效性。

最后，基于 SZ 和 LA 等多源数据集的实验结果表明，本文提出的时空注意力与自适应图卷积联合框架模型在多种复杂场景下的交通流量预测任务中，相较主流基准模型展现出显著优越性。具体而言，在核心性能指标方面，本文提出的模型在 LA 数据集上预测平均绝对误差（MAE）和均方根误差（RMSE）分别较对比模型下降至少 40.70% 和 33.08%。相较于传统图卷积框架，本文采用的自适应图网络学习节点学习机制能有效的缩短模型训练时间。

综上，本文从时空注意力机制、多信息融合、节点自适应学习三个维度提出了一种新的交通流量预测模型。该模型可为新时代智慧交通管理系统提供重要支撑，为优化交通资源配置、缓解交通拥堵、提升城市交通效率提供技术保障。同时，基于自

身灵活的适应性和高效的计算效率，本文提出的新模型在处理大规模交通网络数据是具有明显的优势，具有较强的行业应用推广潜力.

关键词： 交通流量预测；图卷积神经网络；注意力机制；自适应图网络学习

Abstract

Traffic flow prediction is one of the core tasks in intelligent transportation systems, providing key decision support for traffic management and urban planning. However, with the continuous development of cities, the transportation network has become increasingly complex, and its scale has grown exponentially. Traditional traffic flow prediction methods face many new challenges, mainly focusing on the following aspects: 1) the strong spatiotemporal dependencies of traffic flow, how to capture these spatiotemporal correlations; 2) how to fuse multi-source heterogeneous data; 3) how to address the high computational complexity of the problem.

To address these challenges, this study innovatively proposes a joint model based on a spatiotemporal attention mechanism and an adaptive graph convolutional network. The spatiotemporal attention mechanism can adaptively learn important features in both time and space, helping the model focus on key periods and areas that affect traffic flow. The temporal attention mechanism assigns different weights to inputs at different time steps, enabling the model to pay attention to periods of significant traffic flow fluctuations. This mechanism significantly enhances the model's ability to capture nonlinear trends and long-term dependencies. At the same time, the introduction of the spatial attention mechanism effectively alleviates the over-smoothing problem in graph convolution. By dynamically adjusting the interactions between each node and its neighboring nodes, the spatial attention mechanism prevents excessive averaging of information, increases the model's sensitivity to local features, and improves prediction accuracy.

Additionally, in optimizing the graph convolutional network, this study employs an adaptive graph network technique that allows the model to learn and reflect the complex underlying relationships between nodes. This improvement not only simplifies the computational process but also significantly reduces the computational cost when handling large-scale traffic network data, avoiding memory overflow and long processing times, thereby enhancing the model's practicality.

Moreover, this study attempts to incorporate multi-source information into the model by considering external relevant data such as weather conditions and Points of Interest (POI) information. This approach further improves the model's prediction accuracy, demonstrating the effectiveness of multi-source information fusion in traffic flow prediction.

Finally, experimental results based on datasets such as SZ and LA show that the proposed spatiotemporal attention and adaptive graph convolution joint framework model demonstrates significant superiority over mainstream baseline models in traffic flow prediction tasks in various complex scenarios. Specifically, in terms of key performance indicators, The model proposed in this paper achieves at least a 40.70% and 33.08% reduction in Mean Absolute Error (MAE) and Root Mean Square Error (RMSE), respectively, compared to the baseline models on the LA dataset. Compared to traditional graph convolution frameworks, the adaptive graph network learning mechanism used in this study can effectively shorten the model's training time.

In conclusion, this study presents a new traffic flow prediction model from the perspectives of temporal attention mechanism, multi-information fusion, and adaptive node learning. This model provides essential support for the new era of smart transportation management systems and offers technical assurance for optimizing traffic resource allocation, alleviating traffic congestion, and improving urban traffic efficiency. Moreover, due to its flexible adaptability and efficient computational performance, the proposed model has significant advantages in handling large-scale traffic network data and demonstrates strong potential for industry application.

Key words: Traffic Flow Prediction; Graph Convolutional Network; Attention Mechanism; Adaptive Graph Network Learning

目 录

摘 要	I
Abstract	III
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 研究现状	2
1.2.1 经典统计模型的预测方法	2
1.2.2 机器学习预测方法	3
1.2.3 深度学习预测方法	4
1.3 创新点	7
1.4 本文结构	8
第 2 章 图网络基本理论	10
2.1 图概述	10
2.2 图数据应用场景	10
2.3 图拉普拉斯矩阵	11
2.4 图傅里叶变换与图滤波器	12
2.5 图卷积神经网络	15
2.6 GCN 的性质	17
2.7 其他经典交通流量预测模型	19
2.7.1 长短记忆神经网络	19
2.7.2 图嵌入方法	21
2.7.3 T - GCN	23
第 3 章 基于注意力机制与图神经网络的交通流量预测	24
3.1 引言	24
3.2 基于时空注意力机制与图网络结合的交通流量预测方法设计思路	25
3.3 模型具体分析	26
3.3.1 时空注意力机制	26
3.3.2 图滤波器优化	28
3.4 实验结果分析	31
3.4.1 实验细节设置	31

3.4.2 实验结果	32
第 4 章 基于时空注意力机制-自适应图网络的交通流量预测方法	39
4.1 引言	39
4.2 自适应图的设计思路	40
4.3 实验结果分析	42
第 5 章 总结与展望	43
5.1 总结	43
5.2 展望	45
参考文献	47
致 谢	51

插 图

2.1	三类滤波器的频率响应函数 (刘忠雨, 李彦霖和周洋, 2021)	15
2.2	响应函数图像 (马耀, 2021)	18
2.3	LSTM 模型结构图	20
2.4	T-GCN 模型结构图 (胡晓荣, 2023)	23
3.1	模型结构示意图 (Guo et al., 2019)	25
3.2	T - GCN 与 ASTGCN 在 SZ 测试集上预测效果对比	35
3.3	T - GCN 与 ASTGCN 在 LA 测试集上预测效果对比	36
3.4	不同天气状况下速度对比	38

表 格

3.1	SZ 数据集实验结果	33
3.2	LA 数据集实验结果	33
3.3	SZ 数据集消融实验结果	34
3.4	LA 数据集消融实验结果	34
3.5	融合多信息与原始数据预测结果	38
4.1	自适应图网络与原模型对比	42
4.2	自适应图网络与原模型训练时间对比	43

第 1 章 绪论

1.1 研究背景与意义

随着经济社会的快速发展，城市化进程不断加快，交通运输需求日益增加。

交通拥堵成为当前大多数城市面临的一个普遍问题，尤其是大城市，超负荷的交通流量和有限的路网，造成了高峰时段的严重拥堵。根据国内外的研究，交通拥堵不仅仅降低人们的出行效率，还带来了一系列社会经济问题。例如，在北京等一线城市，通勤高峰期的平均车程可能是平时的 2-3 倍 (贾若, 戴昇宏和黄霓, 2021)，导致上班族每天浪费在交通上的时间达到数小时。据估算，全球每年因交通拥堵造成的经济损失已达到数万亿美元。长时间的交通拥堵不仅造成了巨大的能源浪费，也增加了汽车尾气排放，加剧了环境污染。研究揭示，交通拥堵现象每年释放出巨量的二氧化碳及其他有害气体，这不仅对全球气候变化产生了深远影响，也给城市空气质量带来了沉重负担。此外，交通拥堵还直接导致居民生活质量的显著下降，并伴随着交通事故的频繁发生，从而对公共安全构成了更为严峻的挑战。更为严重的是，在高峰时段，交通拥堵限制了公共交通系统的有效承载能力，促使人们更加倾向于依赖私家车出行，这一行为反过来又进一步加剧了交通压力，形成恶性循环。因此，如何准确预测交通流量、优化交通管理、缓解交通拥堵、提高道路利用率，成为了各大城市交通管理部门和研究机构亟待解决的问题。

2019 年中共中央、国务院印发了《交通强国建设纲要》，纲要指出强化前沿关键科技研发，大力发展智慧交通。推动大数据、互联网、人工智能和超级计算等技术与交通行业的深度融合 (中国政府网, 2019)。为了提高交通管理效率，许多城市开始借助交通大数据技术进行智能交通管理。交通大数据技术通过收集来自路面传感器、摄像头、GPS 等设备的数据，分析交通流量变化，预测未来的交通趋势，从而实现了对交通的智能调度和管理。交通流量预测是交通大数据技术中的一个重要应用领域。通过大数据分析，能够对历史交通流量数据进行建模，结合实时数据，提供准确的交通流量预测结果。交通流量预测研究不仅具有重要的理论价值，也对解决城市交通拥堵、提高交通管理水平、促进可持续发展具有重要的现实意义。通过采用大数据和人工智能等技术，城市交通管理可以实现更高效的资源配置和更智能的出行方案。未来，随着技术的不断进步，交通流量预测将在缓解交通压力、减少能源消耗、提高生活质量等方面发挥越来越重要的作用。对于交通流量预测的深入研究，将为城市交通管理提供强有力的决策支持，推动智能交通的普及与发展，最终实现智慧

城市的愿景.

交通预测的难点主要在于时空动态变化, 交通流量受多种因素的影响, 具有高度的随机性和非线性, 这使得对交通状态的预测变得异常复杂. 为了解决这一问题, 许多研究者在交通预测领域进行了广泛的探索, 提出了各种方法. 传统的统计方法和机器学习方法在处理交通流量数据时, 尽管能够在一定程度上反映交通的变化趋势, 但仍然存在显著的不足, 模型预测效果很大程度上取决于参数预设且对历史数据要求较高, 尤其是在应对交通流量这种复杂的随机非线性数据时, 预测精度和鲁棒性都受到限制. 浅层神经网络虽然能对数据进行拟合, 但难以有效捕捉到交通流中的深层次规律. 近年来, 基于交通参与对象特点的现代方法逐渐引入了图神经网络等技术. 这些方法利用图结构来建模交通路网, 能够更好地反映道路之间的空间依赖关系和交通流的时空动态. 然而, 现有的图方法仍然面临一些挑战, 特别是在忽略路网节点间的动态交互效应、序列学习时的梯度爆炸/消失问题以及难以有效学习交通流的非线性扩散机制等方面. 为了弥补这些不足, 本文提出了一种结合注意力机制与图神经网络的模型, 以期通过对节点的动态特征进行加权学习, 从而提升交通流量预测的准确性. 此外, 本文还提出了一种自适应图模型, 旨在捕捉交通节点间的潜在关系, 为解决现有模型的不足提供新思路.

1.2 研究现状

交通预测方法的分类在现有文献中呈现两种主要形态: 动态仿真与数据驱动型方法. 基于数学工具(微分方程等)和物理原理的运用, 交通流量预测得以通过计算模拟实现的是动态仿真方法(Vlahogianni, 2015). 系统编程的复杂性伴随着该方法的实施过程, 计算能力的巨大消耗亦不可忽视, 稳态的达成由此受到制约. 近年来显著进步的交通数据采集与存储技术使得研究者的关注点发生了转移, 数据驱动建模方法正逐渐成为主流选择方向.

1.2.1 经典统计模型的预测方法

鉴于交通流量数据的时序特征, 早期研究中多采用时间序列方法对交通流量数据进行统计建模, 再基于模型对未来交通流量进行预测. Williams and Hoel(2003) 基于交通数据非平稳性, 提出使用 ARIMA 方法对数据进行建模和预测. 鉴于 ARIMA 只能描述单个时间序列的变换, 无法同时多个相关时序的动态演变过程, 而 VAR(向量自回归)模型不仅能够捕捉单个变量的时间依赖性, 还能够揭示多个变量之间的反馈效应(Sims, 1980). 例如, 在交通流量预测中, 不同道路流量可能会相互影响,

VAR 模型可以帮助分析这些道路流量之间的相互依赖, 并进行联合预测, 如孙天瑀 (2022) 构建交通网络 VAR 模型实现多节点联动预测, 通过特定的向量自回归过程, 可以更好地识别出不同节点之间的依赖模式, 有效提升了交通预测的准确性. 卡尔曼滤波由 Kalman 在 1960 年提出的模型 (Kalman, 1960), 是一种广泛应用于动态系统状态估计的递归算法, 特别适用于噪声较大的时间序列预测. 该方法基于贝叶斯理论, 通过对系统的状态进行连续的预测和更新, 能够有效估计系统的真实状态, 并减少测量噪声的影响. 张垚旖 (2021) 将卡尔曼滤波与 CatBoost 融合, 并应用于交通流量预测, 融合模型能够分辨哪些是噪声, 哪些是反映交通流突变的细微线索.

以上几种模型或方法的研究, 都是以数理统计为基础的. 这一类模型有些需要严谨的超参数设置, 在 VAR 模型中, 每个变量都与自身和其他变量的滞后值进行回归. 因此, 模型的复杂性取决于所选的滞后期数. 滞后期数的选择通常依赖于数据的特征和经验判断, 一般通过信息准则 (如 AIC、BIC) 来确定合适的滞后期数. 滞后期数的选择直接影响模型的预测能力和计算复杂性, 滞后期数过多可能导致模型过拟合, 而滞后期数过少可能无法捕捉到足够的动态信息. 通常这些方法使用需要数据满足某些前提条件, 但实际交通数据太复杂, 无法满足这些前提条件, 因此此类模型在实际运用中通常表现欠佳.

1.2.2 机器学习预测方法

由于经典统计方法不适合处理复杂和动态的时间序列数据, 因此在实际应用中通常性能较差. 越来越多的研究开始转向使用机器学习方法预测交通流量. 机器学习方法在处理高维数据和揭示复杂的非线性关系时具有一定的优势. K 近邻 (KNN) 和支持向量回归 (SVR) 是交通流量预测中常用的两种机器学习算法.

KNN 模型在交通预测中的应用, 关键在于如何选择合适的邻居相似度度量方法以及如何利用邻居的信息进行预测. 于滨, 邬珊华, 王明华等 (2012) 通过结合时间参数和空间参数, 从时空两个维度衡量样本之间的距离. 相比仅考虑时间因素的方法, 该方式在预测性能上取得了显著提升.

SVM 通过核函数将数据映射到高维空间, 从而捕捉到变量间复杂的非线性关系. 基于 SVR 技术, Jeong, Byon, Castro-Neto et al. (2013) 将权重参数的动态调整与支持向量回归法融合用于短期交通流量预测, 权重参数的动态调整使得不同时段交通流特征差异性被充分考虑于该模型中. Lippi, Bertini and Frasconi (2013) 在 SVR 模型中通过添加描述季节性信息的函数, 构建新 RBF 函数, 辅助 SVR 模型学习交通的季节性信息, 有效提高了预测精确性.

相较于经典统计模型，尽管机器学习方法在预测精度和使用灵活性上具有很大优势，但也存在一些显著的缺点：

(1) 数据数量和质量上的强依赖性。充分的历史交通、天气、道路状况、节假日信息等信息在交通流量预测不可或缺。若数据稀缺或存在缺失，模型的预测能力将大大降低。例如，交通流量在某些地区或特定时间段的数据可能比较稀缺，这会导致模型无法有效地学习到数据的规律，影响其预测效果。此外，数据的质量至关重要，错误标注或噪声干扰会对模型的训练和预测产生较大的负面影响。

(2) 过度依赖人工特征选取，难以捕捉突发事件的隐含模式。

(3) 计算复杂度过高，计算资源和计算时间的开销过大。

(4) 模型泛化能力受限于训练数据覆盖面，易对局部数据波动产生过度反应，导致预测效果大打折扣。

1.2.3 深度学习预测方法

在语音识别任务以及图像处理领域方面，深度学习技术已获得诸多突破性成果，由此引发研究者们对时空数据预测问题的关注度提升。具有强大表征学习能力的深度神经网络模型，正被越来越多地尝试运用于时空序列的建模过程当中，尤其是在交通流量、气象预报、能源需求、环境监测等领域取得了显著进展。时空数据预测不仅涉及时间维度的变化，还要考虑空间上的相互依赖性，因此深度学习为其提供了强大的工具。通过利用深度神经网络的高效特征学习能力，研究者能够从复杂的时空数据中提取出有效的特征模式，从而提高预测精度。

鉴于城市交通数据时间和空间上的相依性，卷积神经网络 (CNN)、循环神经网络 (RNN)、长短记忆神经网络 (LSTM) 被广泛使用 (Zhang, Zheng and Qi, 2017; Hochreiter and Schmidhuber, 1997)。进一步，Wu and Tan (2016) 及 Yao et al. (2018a) 等研究提出融合 CNN 空间特征提取与 LSTM 时序建模能力的 CLTFP 框架。Shi et al. (2015) 提出一个具有嵌入卷积层的扩展全连接 LSTM (FC-LSTM)。这些研究从不同方式融合卷积神经网络 (CNN) 和长短期记忆网络 (LSTM)，能够同时捕捉到空间上的局部特征和时间上的全局趋势，从而提升了交通流量预测的精度和鲁棒性。Yao et al. (2018b) 提出了一种时空动态网络 (ST-DN)，用于出租车需求预测任务。该模型可以动态地学习不同地理位置之间的相似性和依赖关系，并根据实时交通和环境变化调整预测。

另一方面，为缓解深度网络中梯度消失问题，增强模型长期依赖的捕捉能力，Zhang et al. (2018) 通过引入残差连接提出 ST-ResNet 模型。

尽管这些深度学习模型在时空数据预测中取得了显著的成果，但它们仍然存在

一定的局限性。首要限制在于多数模型对输入数据的格式要求严苛，需为标准的二维或三维网格结构。这种局限性导致模型难以直接处理具有非规则空间分布特性的城市交通流量数据。需将城市空间划分为固定尺寸的网格单元（如 $1\text{km} \times 1\text{km}$ ），这种人为的空间划分方式既无法适应离散化、异质化、动态变化的交通需求。例如，商业中心与远郊住宅区虽在地理位置上相距甚远，却可能共享相似的通勤高峰特征，这种跨区域的相关性超出了传统卷积神经网络（CNN）的建模能力范围。

在时间序列处理方面，现有方法主要依赖 RNN 及其衍生架构来捕获时序依赖关系。然而，这种链式结构在设计上存在固有缺陷：每个时间步的处理必须依次迭代，导致长序列建模时不可避免地出现信息衰减问题。此外，当前模型普遍缺乏对时间维度动态特性的深入考量，未能充分认识到前序时间步对当前预测的影响权重随时间变化的本质特征。这种静态的时间相关性处理方式，使得模型难以适应交通流量在不同时间段（如工作日与节假日、高峰与平峰时段）的动态演化规律，进一步制约了 CNN+RNN 混合架构在实际应用中的表现。这些技术瓶颈共同制约了深度学习模型在复杂交通场景中的泛化能力与鲁棒性，亟需发展新型时空建模框架以突破现有局限。

为了克服这些问题，近年来，研究者们开始探索更为灵活的深度学习架构，如图神经网络（GNN）和图卷积网络（GCN）。这些模型能够处理图形结构数据，在交通流量预测中尤为有效，因为城市交通网络本质上就是一个由路网、交通节点和路段组成的图形结构。通过引入图卷积网络，模型能够在非规则的交通网络上学习到时空依赖关系，从而实现更为精确的数据预测。基于图卷积网络（GCN）的短期交通流量预测也已取得令人瞩目的成就。然而，中长期（一小时及以上）的交通预测仍缺乏令人满意的进展，究其原因是在存在以下不足和挑战：

1. 动态时空建模局限性。道路网络中传感器之间的交通条件的相关性随着时间的推移而显著变化（例如，在高峰时间之前和期间）。这种相关性的动态变化导致基于静态图结构的方法难以准确建模交通流的真实演变过程。静态图无法及时反映节点间关系的时变特性，进而影响模型对复杂交通状态的感知与预测能力。因此，构建能够捕捉时空依赖变化的图模型，成为提升交通预测精度的关键方向。

2. 对于误差传播的敏感性。当需要在一个长期尺度下进行预测时，人们主要使用的主体框架即为循环神经网络与图网络结合的方法，在该模型中每个时间步中的小误差可能会放大。这种错误的传播使预测对更长未来的时间片段具有高度的挑战性。

近年来的研究中，注意机制被广泛应用于自然语言处理、图像字幕和语音识别

等各种任务中。其核心目标在于，从所有输入信息中筛选出对于当前任务而言具有相对重要性的部分。在图像描述任务的研究过程中，两种不同类型的注意机制被 Xu et al. (2015) 提出，同时采用可视化的技术手段直观呈现了该机制的运作效果。处理图结构数据时，基于自我注意层的神经网络架构被 Velickovic et al. (2018) 所采用，实例表明该方法在图节点分类任务中取得了突破性的成果。针对时间序列预测问题，一个包含多层次注意力结构的网络模型由 Liang et al. (2018) 设计完成，由此可见注意力机制能够自适应地学习多个地理传感器时序数据间的关联特性。

作为一种新兴技术，图注意力机制正逐步成为交通流量预测领域的关键技术。交通流序列包括流量、速度、占有率等多个因素，它们之间相互作用，要准确预测交通流量，必须深入挖掘这些因素之间的非线性关系。Guo et al. (2019) 创新性地构建了一种基于注意力机制的新型时空图卷积网络模型 (ASTGCN)，该模型面向交通流量预测问题域展开探索。由三个相互独立的子模块构成 ASTGCN 模型的核心架构，这些子模块分别对应于交通流量数据中存在的三种典型时间模式特性：短期动态性、日周期性以及周周期性。具体而言，每个子模块内部又可划分为两个关键组成部分：

(1) 时空注意机制，以有效地捕获交通数据中的动态时空相关性。具体来说，空间注意被用来模拟不同位置之间复杂的空间相关性。采用时间注意法来捕捉不同时间之间的动态时间相关性；

(2) 时空卷积，通过时间卷积与空间卷积的双轨建模方式。它包括用于从原始的基于图的交通网络结构中捕获空间特征的图卷积，以及用于描述来自附近的时间切片的依赖关系的时间维数上的卷积。传统卷积运算的运用在此研究中呈现出新的可能性，与图神经网络形成互补态势。

Zheng et al. (2020) 针对时空因素，提出了一种图注意网络 (GMAN) 来预测道路网络图上不同位置前方时间步长的交通情况。GMAN 采用了一种编码器-解码器架构，其中时空注意模块构成编码器和解码器的主要组件。时空因素对交通状态的影响通过这种结构得以建模。流量特征编码由编码器完成，而输出序列预测任务则交由解码器执行。转换注意力层作为连接编码器与解码器的纽带，其功能是将已编码流量特征转化为未来时段的序列表征。作为输入解码器前的表征，历史时段与未来时段的直接关联通过转换注意机制建立。误差在预测时段间传播的现象由此得到有效抑制。在两个真实世界的交通预测任务（即交通量预测和交通速度预测）上的实验结果表明了 GMAN 的优越性。他们同样提出了空间和时间注意机制来建模动态空间和非线性时间相关性。此外，还设计了一种门控融合来自适应地融合由空间和时间注意机制提取的信息。

注意力机制对于图网络模型具有两方面的意义。传统的图卷积网络（GCN）在交通流量预测中常常会遇到“过平滑”问题，即多次图卷积操作后，节点的特征逐渐趋于一致，甚至相同。这种现象在交通流量预测中尤为不利，因为每个节点（如每个路段或区域）通常具有独特的时空特征。注意力机制的引入有利于解决这个问题。通过注意力机制，图神经网络能够根据节点之间的关系自适应地调整信息传播的权重，而不是简单地将所有邻接节点的特征平均或叠加。这样，模型能够在信息传播过程中，更加关注重要邻接节点，避免信息过度平滑和丢失。此外，注意力机制能够帮助网络识别出不同节点之间的不同影响程度。例如，在交通流量预测中，某些路段可能因交通管制、事故或突发事件而对预测结果产生更大影响，而其他路段则可能影响较小。注意力机制让模型自动学习到这些时空依赖关系，从而增强了模型对复杂交通网络的适应能力，提升了预测的准确性。

因此，结合注意力机制后，图神经网络能够在保持节点特征多样性的同时，有效避免过平滑问题，从而提升交通流量预测模型的性能。基于上述启发，本文主要的预测方法也将聚焦于图卷积与注意力机制的融合。

随着图网络研究的深入，一些研究开始对图卷积框架提出质疑。Wu, Pan, Long et al. (2019) 认为传统的预定义图模型未能充分捕捉复杂交通流预测场景中的空间依赖性，因此提出通过节点嵌入的方式构建自适应图邻接矩阵，为交通流预测中的空间关系建模提供了一种新思路。Bai, Yao, Li et al. (2020) 则设计了节点自适应参数学习模块和数据自适应图生成模块，并与 GRU 网络结合，能够自动学习交通流数据之间的时空相关性。这两类方法的出现使得研究者可以跳出深奥的图理论，摆脱图的连通性信息的限制，也不再需要进行一些图拉普拉斯矩阵的运算，极大降低运算成本。本文将基于此思想改进融合图卷积与注意力机制框架。

1.3 创新点

本文创新性地提出了一种融合时空注意力机制与改进图卷积网络（GCN）的方法，以精准预测交通流量。该方法的主要创新之处体现在以下几个关键方面：

首先，本文引入了时间注意力机制，以弥补传统 RNN 和 LSTM 在预测序列中的不足。这些传统模型通常依赖固定的时间步长，难以捕捉交通流量在不同时间段的动态变化。相比之下，时间注意力机制通过自适应地为不同时间点分配权重，使模型能够聚焦于交通流量波动较大的时段，从而更精确地捕捉交通流量的时间变化规律。这一机制不仅提升了模型的预测准确性，还增强了对非线性和长时依赖关系的建模能力。

其次，本文采用空间注意力机制来缓解图卷积网络中的过平滑问题。在处理大规模交通图时，图卷积网络可能会面临不同节点表示过于相似的问题，导致模型失去辨别能力。为了解决这一问题，本研究引入了空间注意力机制，通过为图中的每个节点分配不同的注意力权重，使得节点间的信息传播更加灵活，有效避免了过度平滑现象的发生，进一步提升了模型的表现力。此外，在时空注意力机制与图网络的框架上进行了多信息的融合操作，验证了该框架对于多源信息融合的适应性。

在图网络设计方面，对图卷积操作进行了改进。考虑到交通网络规模庞大带来的计算开销，本文使用了一种先进的图滤波器结构，显著降低了计算复杂度。这种改进尤其适用于大规模图数据，有效减少了内存和计算资源的消耗，提高了计算效率。同时，该设计使得模型能够在更广泛的交通网络中进行有效预测。

此外，在论文的第二部分研究中提出了一种自适应图卷积操作。该操作摒弃了传统的预先定义的邻接矩阵，转而引入自适应学习机制，使模型能够根据实际数据中的时空依赖关系动态学习最合适的邻接矩阵。这一创新使得模型在进行图卷积时能够根据不同任务需求自动调整邻接矩阵，从而提高了模型的灵活性和表达能力。同时，由于不再依赖固定的邻接矩阵，计算量得以显著减少，进而加快了训练和推理过程，进一步提升了计算效率。

1.4 本文结构

现就本文的行文思路作如下总结：

第一章为绪论部分。首先介绍交通流量预测的背景意义和应用前景；接着介绍交通流预测的国内国外研究现状；随后介绍论文的两个主要研究内容，主要的创新点和使用的技术手段；最后概述全文结构。

第二章主要介绍相关模型的基本理论。章节首先介绍了图的相关理论支撑，图卷积背后的原理以及图卷积模块设计思路，为下文对于图网络层改进做铺垫。第二章还列举出交通流预测问题中的经典算法，并对其设计思路及原理进行简单介绍，作为后文基线模型使用。

第三章为本文的第一个主要部分。首先介绍基于时空注意力机制与图卷积融合的交通流预测方法整体流程框架；然后介绍网络的基本组成部分，阐明了每个部分的网络结构，将各个部分构建成为一个完整的交通流预测系统；最后，针对本章所提算法，在经典的交通流数据集上进行验证，将实验结果和现有方法进行比较，证明了该算法与之前的 GCN+RNN 框架相比，有效的提升了预测结果的准确度。随后，并提出了基于该框架下的多信息融合思路。

第四章为本文的第二个主要部分。章节首先介绍自适应图网络模型的交通流预测方法整体流程框架；然后对设计的动态图生成展开详细介绍；最后通过在多个数据集上进行对比实验，验证了算法在添加上述模块后有效提升了交通流数据的预测精度并减少推理时间。

第五章对全文进行总结，并对所提方法的改进空间和未来研究方向提出展望。

第 2 章 图网络基本理论

2.1 图概述

图由顶点和边构成,用以描述对象之间的关系.形式化地,图可以表示为 $G = (V, E)$, 其中: V 是顶点集合,表示对象. E 是边集合,表示顶点之间的关系.

邻居: 在图中,若两个顶点之间存在一条边,则称它们为邻居.

例如,在无向图 $G = (V, E)$ 中,若存在边 $e = \{v_i, v_j\}$, 则顶点 v_i 和 v_j 是邻居.

邻居集合: 对于顶点 v , 其邻居集合 $N(v)$ 定义为: $N(v) = \{u \in V \mid \{v, u\} \in E\}$.

度: 顶点的度是与该顶点直接相连的边的数量. 在无向图中, 顶点 v 的度 $D(v)$ 为: $D(v) = |N(v)|$.

在有向图中, 顶点的度分为入度与出度. 入度是以该顶点为终点的边的数量. 出度是以该顶点为起点的边的数量.

k 阶子图是包含 k 个顶点及其之间所有可能边的子图. 例如, 当 $k = 2$ 时, k 阶子图是由两个顶点和它们之间的边构成的最小子图. 当 $k = 3$ 时, k 阶子图可能是一个三角形, 包含三个顶点和三条边. k 阶子图常用于分析网络中的局部结构, 如社交网络中的三角形闭包现象.

路径与连通性: 路径是从一个顶点到另一个顶点的边序列. 路径可以是简单路径(不重复顶点)或回路(起点与终点相同的路径). 若在图中任意两个顶点间都存在路径, 则图是连通的.

邻接矩阵: 邻接矩阵是描述图的一种矩阵表示形式. 对于一个包含 n 个顶点的图, 其邻接矩阵 A 是一个 $n \times n$ 的矩阵, 满足以下条件: 若顶点 i 和顶点 j 之间存在边, 则 $A[i][j] = 1$ (或权值 w); 若顶点 i 和顶点 j 之间不存在边, 则 $A[i][j] = 0$. 在无向图中, 邻接矩阵是对称的; 在有向图中, 矩阵的对称性不一定成立.

2.2 图数据应用场景

交通网络: 图数据是一种基于节点和边的结构化数据形式, 广泛应用于需要描述复杂关系的场景. 交通网络是图数据的典型应用之一. 在交通网络中, 城市中的道路、铁路、公交线路可以表示为图中的边, 交叉路口、车站等可作为节点. 通过图数据分析, 可以实现最短路径规划、交通流量优化、事故风险评估等功能. 例如, 导航软件利用图算法快速找到最优路径, 实时避开拥堵区域, 从而提升出行效率. 此外, 公共交通系统中可以通过图数据优化线路布局, 提升整体运输能力.

社交网络：在社交网络中，用户和用户之间的关系可以建模为图，节点表示用户，边表示好友关系或互动行为。通过图算法可以挖掘关键节点（如意见领袖），分析信息传播路径和社区结构。典型应用包括推荐好友、反欺诈检测和舆情分析等。

知识图谱构建：知识图谱通过图结构将概念、实体及其关系进行建模，广泛应用于搜索引擎、智能问答和语义分析中。它可以将自然语言中的信息转化为可查询的结构化数据，帮助实现精准检索、上下文理解和多跳推理。

供应链管理：在供应链中，企业、仓库、运输路径可以建模为图，通过分析节点和边的权重，优化物流路径、降低运输成本。基于图数据，可以提前发现瓶颈环节，保障供应链的稳定性，提高资源利用效率。

2.3 图拉普拉斯矩阵

图信号处理是一门结合图论与信号处理的新兴学科，用于研究定义在图结构上的信号。图的拉普拉斯矩阵是分析图信号的重要工具，具有丰富的数学性质和实际意义。本节将简要描述图的拉普拉斯矩阵的定义、形式及其与拉普拉斯算子的关系，并论述其在反映图信号局部平滑度及构建二次型中的重要作用。

图的拉普拉斯矩阵是描述图结构的重要工具，广泛应用于图信号处理、网络分析和机器学习中。对于一个无向图 $G = (V, E)$ ，其拉普拉斯矩阵定义为：

$$L = D - A, \quad (2.1)$$

其中， D 是度矩阵 (Degree Matrix)：一个对角矩阵，其对角线元素 $D[i, i]$ 表示顶点 i 的度数。 A 是邻接矩阵 (Adjacency Matrix)：矩阵的元素 $A[i, j]$ 表示顶点 i 和 j 是否相连。

拉普拉斯矩阵根据其形式可以分为标准型和正则型。

标准型拉普拉斯矩阵 L 定义为 $L = D - A$ 。其元素形式为：若 $i = j$ ， $L[i, j] = D(i)$ (顶点的度数)。

若 $i \neq j$ 且 i 与 j 相连， $L[i, j] = -1$ 。

若 $i \neq j$ 且 i 与 j 不相连， $L[i, j] = 0$ 。

正则型拉普拉斯矩阵是对标准型进行归一化处理的结果，其定义为：

$$L_{\text{norm}} = I - D^{-1/2} A D^{-1/2}, \quad (2.2)$$

这里， I 是单位矩阵， $D^{-1/2}$ 是度矩阵的平方根倒数。正则化矩阵通过对顶点的度数进行标准化，可以更好地平衡图中节点的影响，特别适用于具有不同度分布的图 (Chung, 1997)。

拉普拉斯矩阵来源于连续空间中的拉普拉斯算子, 是其在离散图结构上的推广形式. 在连续空间中, 拉普拉斯算子用于计算函数的二阶导数, 用于描述局部变化率. 其定义为:

$$\Delta f = \sum_{i=1}^n \frac{\partial^2 f}{\partial x_i^2}. \quad (2.3)$$

在离散图结构中, 拉普拉斯算子退化为拉普拉斯矩阵. 具体地, 若定义图信号为一个顶点上的函数值向量 $f = [f_1, f_2, \dots, f_n]^T$, 拉普拉斯矩阵作用于图信号时表示为:

$$Lf = Df - Af, \quad (2.4)$$

这里, Lf 的结果描述每个顶点的值与其邻居顶点值之间的差异. 拉普拉斯矩阵本质上是一个离散的差分算子, 用于反映图上信号的变化程度.

拉普拉斯矩阵是一个反映图信号局部平滑度的算子. 对于一个图信号 f , 拉普拉斯矩阵可以用来度量信号在图上的平滑程度, 直观地描述信号在邻域中的变化情况. 拉普拉斯矩阵可以定义一个非常重要的二次型, 称 $\sum_{e_{ij} \in E} (x_i - x_j)^2$ 为图信号的总变差, 总变差是一个标量, 它将各条边上的信号的差值平方进行加和, 刻画了图信号整体的平滑度.

$$x^T Lx = \sum_{v_i} \sum_{v_j \in N(v_i)} x_i (x_i - x_j) = \sum_{e_{ij} \in E} (x_i - x_j)^2. \quad (2.5)$$

这一二次型刻画了图信号的平滑性: 当相邻顶点之间的信号值差异较小时, 该值较小; 当信号值差异较大时, 该值较大. 由此可见, 拉普拉斯矩阵是一个用于分析信号平滑度的重要工具.

可见拉普拉斯矩阵在图信号处理中具有重要意义, 它反映了图信号的局部变化, 能用来衡量图信号的平滑性和不均匀性. 它在谱分析中起核心作用, 例如通过特征值分解对图进行聚类或降维. 另外拉普拉斯矩阵在图卷积神经网络 (GCN) 等机器学习模型中被广泛用作构建图滤波器的基础.

2.4 图傅里叶变换与图滤波器

数字信号处理领域中, 具有基础性地位的当属傅里叶变换方法. 从时域空间向频域空间的转换过程, 都是由该变换方法实现的. 滤波操作与卷积操作等信号处理技术, 其完备的理论定义均建立在该变换基础之上. 去噪任务、压缩任务以及重构

任务等工程实践应用，也能从中获得明确的理论指导。傅里叶变换同样存在于图信号处理领域，此处将给出相应定义。空域视角到频域视角的转换过程，正是图信号傅里叶变换所要实现的目标，频域视角也将为信号处理带来极大便利。

假设图 G 的拉普拉斯矩阵为 $L \in \mathbb{R}^{N \times N}$ ，由于 L 是一个实对称矩阵，根据实对称矩阵都可以被正交对角化，可得：

$$L = V \Lambda V^T = \begin{bmatrix} \vdots & \vdots & \cdots & \vdots \\ \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_N \\ \vdots & \vdots & \cdots & \vdots \end{bmatrix} \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_N \end{bmatrix} \begin{bmatrix} \cdots & \mathbf{v}_1 & \cdots \\ \cdots & \mathbf{v}_2 & \cdots \\ \cdots & \vdots & \cdots \\ \cdots & \mathbf{v}_N & \cdots \end{bmatrix}. \quad (2.6)$$

$V \in \mathbb{R}^{N \times N}$ 是一个正交矩阵，即 $VV^T = I$ 。 $V = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_N]$ 表示 L 的 N 个特征向量，由于 V 是一个正交矩阵，这些特征向量都是彼此之间线性无关的单位向量。 λ 表示第 k 个特征向量对应的特征值，特征值从小到大排列，即 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$ 。

对于任意给定的向量 x ，拉普拉斯矩阵的二次型 $x^T L x = \sum_{v_i} \sum_{v_j \in N(v_i)} x_i (x_i - x_j) = \frac{1}{2} \sum_{e_{ij} \in E} (x_i - x_j)^2 \geq 0$ ，因此拉普拉斯矩阵是一个半正定型矩阵，其所有的特征值均大于等于 0。进一步，可知： $L \mathbf{1} = 0$ ，因此拉普拉斯矩阵具有最小的特征值 0，即 $\lambda_1 = 0$ 。另外可以证明，对于 L_{sym} ，其特征值存在一个上限： $\lambda_N \leq 2$ 。

对于任意一个在图 G 上的信号 x ，其图傅立叶变换为：

$$\tilde{x}_k = \sum_{i=1}^N V_{ki}^T x_i = \langle \mathbf{v}_k, x \rangle. \quad (2.7)$$

称特征向量为傅里叶基， $\tilde{x}_k$ 是 x 在第 k 个傅里叶基上的傅里叶系数。从定义式上可以看到，傅里叶系数实际上表示了图信号在傅里叶基上的投影，衡量了图信号与傅里叶基之间的匹配程度。通过矩阵运算，可以计算出所有傅里叶系数：

$$\tilde{x} = V^T x, \tilde{x} \in \mathbb{R}^N. \quad (2.8)$$

由于 V 是一个正交矩阵，对上式左乘 V ，则： $V \tilde{x} = V V^T x = I x = x$ ，即：

$$x = V \tilde{x} \in \mathbb{R}^N. \quad (2.9)$$

于是可以将逆图傅立叶变换定义为：

$$x_k = \sum_{i=1}^N V_{ki} \tilde{x}_i, \quad (2.10)$$

图滤波器是指对图信号频谱中不同频率成分的强度进行放大或抑制的操作。假设图滤波器为 $H \in \mathbb{R}^{N \times N}$, $H: \mathbb{R}^N \rightarrow \mathbb{R}^N$, 令输出图信号为 y , 则:

$$y = Hx = \sum_{k=1}^N (h(\lambda_k) \tilde{x}_k) v_k. \quad (2.11)$$

可以清楚地看到增强还是衰减是通过 $h(\lambda)$ 项来控制的。对上式进行变换:

$$\begin{aligned} y = Hx &= \sum_{k=1}^N (h(\lambda_k) \tilde{x}_k) v_k = \begin{bmatrix} \vdots & \vdots & \cdots & \vdots \\ v_1 & v_2 & \cdots & v_N \\ \vdots & \vdots & \cdots & \vdots \end{bmatrix} \begin{bmatrix} h(\lambda_1) \tilde{x}_1 \\ h(\lambda_2) \tilde{x}_2 \\ \vdots \\ h(\lambda_N) \tilde{x}_N \end{bmatrix} \\ &= V \begin{bmatrix} h(\lambda_1) & & & \\ & h(\lambda_2) & & \\ & & \ddots & \\ & & & h(\lambda_N) \end{bmatrix} \begin{bmatrix} \tilde{x}_1 \\ \tilde{x}_2 \\ \vdots \\ \tilde{x}_N \end{bmatrix} \\ &= V \begin{bmatrix} h(\lambda_1) & & & \\ & h(\lambda_2) & & \\ & & \ddots & \\ & & & h(\lambda_N) \end{bmatrix} V^T x \end{aligned} \quad (2.12)$$

因此, 也可以得到 H 的形式:

$$H = V \begin{bmatrix} h(\lambda_1) & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & h(\lambda_N) \end{bmatrix} V^T = V \Lambda_h V^T. \quad (2.13)$$

相较于拉普拉斯矩阵, H 矩阵只在对角与边坐标上时才有可能取非零值。从运算角度看, Hx 代表在每个节点的局部子图上进行变换。通常, 满足此性质的矩阵称为图位移算子, 例如, 拉普拉斯矩阵和邻接矩阵。

称 Λ_h 为图滤波器 H 的频率响应矩阵, 对应的函数 $h(\lambda)$ 为 H 的频率响应函数, 不同的频率响应函数可以实现不同的滤波效果。在信号处理中, 常见的滤波器有 3 类: 低通滤波器、高通滤波器、带通滤波器 (见图 2.1)。

低频成分被低通滤波器所保留, 信号中平滑部分由此得到凸显; 从 b 图中可以看出, 高频成分则由高通滤波器实现选择性保留, 快速变化区域成为重点关注对象; 从 c 图中可以看出, 特定频段成分的保留通过带通滤波器完成。




图 2.1 三类滤波器的频率响应函数 (刘忠雨, 李彦霖和周洋, 2021)

2.5 图卷积神经网络

在网络设计领域内, 存在着若干关键性思路值得探讨. 频率响应矩阵的参数化过程首先需要被关注. 图卷积运算与图滤波操作本质相同. 作为图滤波算子的核心构成要素, 频率响应矩阵的重要地位由此凸显. 因此, 对该矩阵实施参数化处理具有明显必要性. 基于此考量, 便可以顺理成章定义如下所示的神经网络层结构:

$$X' = \sigma \left(V \begin{bmatrix} \theta_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \theta_N \end{bmatrix} V^T X \right) = \sigma (V \text{diag}(\theta) V^T X) = \sigma(\theta X). \quad (2.14)$$

其中 $\sigma(\cdot)$ 是激活函数, $\theta = [\theta_1, \theta_2, \dots, \theta_N]$ 是需要学习的参数, $\odot$ 是对应的需要学习的图滤波器, X 是输入的图信号矩阵, X' 是输出的图信号矩阵.

这个设计理念虽然直观且易于理解, 存在显著问题的是, 引入的学习参数量级过大, 与图中节点数呈现正相关. 对于大规模图数据而言, 上亿节点的图尤其常见, 容易出现过拟合的结果. 因此, 该网络层设计思路导致学习参数规模产生膨胀化趋势, 直接影响了模型的泛化性能.

实际图数据中, 集中于低频段的往往是信息的有效部分, 高频段的信息承载量呈现出明显的弱化态势. 设置多个维度的自由度以进行图滤波器设计, 并不合理, 有些频率的学习需求并不显著.

Defferrard, Bresson and Vandergheynst (2016) 提出了一种新的图卷积神经网络方法, 旨在提高图数据处理的效率和性能. 该方法基于图的谱理论, 通过快速局部化的频谱滤波器来实现卷积操作. 这些滤波器在频谱域上进行设计, 使得卷积操作不仅能有效地处理图中的节点, 还能捕捉节点之间复杂的结构关系. 他们提出了一个新型的图卷积框架, 通过频谱滤波器来代替传统的邻接矩阵操作, 避免了昂贵的计算成本. 其主要思想方法是将拉普拉斯矩阵的多项式表示转换为一种可以进行学习的形

式，以便更好地拟合不同的频率响应函数。具体如下：

$$X' = \sigma \left(V \left(\sum_{k=0}^K \theta_k \Lambda^k \right) V^T X \right) = \sigma (V \text{diag}(\psi\theta) V^T X), \quad (2.15)$$

多项式系数向量由 $\theta = [\theta_1, \theta_2, \dots, \theta_N]$ 构成，作为网络层中真正需要被学习到的参数量化表征。区别于先前论述的方法，参数量 K 在该框架下具备可调控特性。随着 K 数值的增大，频率响应函数所能拟合的最高次数呈现上升态势，就能够刻画输入图信号矩阵与输出图信号矩阵间存在的复杂滤波关联性。相反地，当 K 取值较小时，频率响应函数的拟合能力受限，仅能拟合输入与输出之间较为基础的滤波作用模式。通常，常规情况下设定 $K \ll N$ 即可，可以显著降低模型过拟合情况的发生概率。

在上述两种方法中，虽然网络层的参数量减少，但计算复杂度却因特征分解过程的强依赖性而急剧提升。为了解决这个问题, Kipf and Welling (2016) 提出直接通过邻接矩阵和节点特征的卷积操作来学习节点表示, 对上式进行了限制, 设 $K = 1$, 则:

$$X' = \sigma (\theta_0 X + \theta_1 L X). \quad (2.16)$$

令 $\theta_0 = \theta_1 = \theta$, 则:

$$X' = \sigma (\theta (I + L) X) = \sigma (\theta \tilde{L} X), \quad (2.17)$$

在网络学习过程中数值稳定性的提升方面，研究者Kipf and Welling (2016)进行了探索。受到正则拉普拉斯矩阵的启发，归一化处理被应用于 L 矩阵。定义 $\tilde{A} = A + I$ 的情况下，构建了重归一化形式的拉普拉斯矩阵 $\tilde{L}_{sym} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$ 这一数学表达式。重归一化形式的拉普拉斯矩阵特征值在 $(-1, 1)$ 区间内。由此可见，在多层网络训练过程中使用重归一化的拉普拉斯矩阵能够有效抑制梯度消失或爆炸这类优化难题。

为了加强网络的拟合能力, 并设计了一个参数化的权重矩阵 W 对输入的图信号矩阵进行仿射变换, 于是得到:

$$X' = \sigma (\tilde{L}_{sym} X W). \quad (2.18)$$

相比于用频率响应函数的拟合形式，图卷积层呈现出显著简化性。最终图卷积相应的图滤波器退化为 $\tilde{L}_{sym}$ 这一形式。转换至运算层面，图卷积操作则演变为 $\tilde{L}_{sym} X$ 的矩阵乘积形式。当 X 从信号矩阵转换为特征矩阵时，具有图位移算子性质的 $\tilde{L}_{sym}$ 显现出特殊计算特性。依据矩阵乘法的行向量解释方式可见，该算子的运算过程本质上执行着邻居节点特征向量的聚合化操作。

2.6 GCN 的性质

GCN 能够对图数据进行端对端学习。近年来深度学习技术取得显著进展之际，作为其核心组成部分的端对端学习范式正日益凸显其重要性。实例表明，深度学习所取得的突破性成果在很大程度上依赖于端对端学习机制的有效运作。端对端的学习方法具备从原始数据中自动提取有效特征的能力。需要指出的是，这种高度自动化学习特性的实现过程往往伴随着大量针对特定数据类型的适配性工作。在当前主流深度学习架构中，各种精心设计的网络层或层块结构便是明证。以二维卷积层为例，其对图像数据的特征提取具有显著优势；而长短期记忆网络层则在处理序列数据时表现出独特效能；全局池化层对于宏观特征的捕获同样不可或缺。由此可见，这些专用计算模块必须严格遵循数据内在规律进行优化设计。实施端对端优化的图卷积网络（GCN），相较于本文基线模型采用的图嵌入技术而言，存在着显著差异：当节点特征向量完成拼接操作后即进入固化状态，下游任务产生的监督信号难以有效作用于图数据表示学习过程，这种机制可能导致节点特征表示无法达到最优任务适配度。相反地，完成图数据建模的 GCN 并未采用两阶段处理模式，节点的表示学习与后续任务学习被整合到整体模型框架内进行协同优化。在节点表示学习质量的提升方面，属性信息的补充发挥着重要作用，特别是针对那些结构稀疏性较强的图数据而言。由 GCN 模型实现的是结构信息与属性信息的同步学习过程，结构信息中所蕴含的知识具有独特性，这些知识在属性信息中并不存在，对于节点的准确刻画至关重要。被放置于同一个网络层中进行协同学习的结构信息和属性信息，二者能够共同作用于最终节点表示的形成。由此可见，直接在原始图数据上构建学习过程的 GCN 模型，为图数据的处理提供了一套端对端的解决方案框架化。在相关任务的学习适应性方面，该模型展现出了明显优势性。

GCN 是一个低通滤波器。回到 GCN 的核心计算式 $\tilde{L}_{sym}XW$ 上，体现图滤波的地方就在于左乘了一个重归一化形式的拉普拉斯矩阵 $\tilde{L}_{sym}$ ，要确定是否为低通滤波，我们就必须去研究 $\tilde{L}_{sym}$ 对应的频率响应函数 $p(\lambda)$ 的性质。

$$\tilde{L}_{sym} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} = \tilde{D}^{-1/2} (\tilde{D} - L) \tilde{D}^{-1/2} = I - \tilde{D}^{-1/2} L \tilde{D}^{-1/2} = I - \tilde{L}_s. \quad (2.19)$$

由于 $\tilde{L}_s$ 可以被正交对角化，因此设 $\tilde{L}_s = V \tilde{\Lambda} V^T$ 是 $\tilde{L}_s$ 的特征值，可以证明， $\tilde{\lambda}_i \in [0, 2]$ 。因此 $\tilde{L}_{sym}$ 可以改写成：

$$\tilde{L}_{sym} = I - V \tilde{\Lambda} V^T = V (I - \tilde{\Lambda}) V^T. \quad (2.20)$$

显然, 其频率响应函数为 $p(\lambda) = 1 - \tilde{\lambda}_i, \in (-1, 1]$, 该函数是一个线性收缩的函数, 因此能起到对图信号进行低通滤波的作用. 如果将信号矩阵 X 不断左乘 K 次 $\tilde{L}_{sym}$, 则对应频率响应函数为 $(1 - \tilde{\lambda}_i)^K$, 图 2.2 为该函数的图像:




图 2.2 响应函数图像 (马耀, 2021)

从图中可以看到, 随着 K 的增大, 频率响应函数在低频段上有着更强的缩放效果, 因此是一种更强效应的低通滤波器. 这种堆叠式的滤波操作, 在一定程度上解释了多层 GCN 模型对于信号的平滑能力. 事实上, 为了更好地突出这种能力、减少模型的参数量, 有些研究直接将多层 GCN 退化成 $o(\tilde{L}_{sym} X W)$.

Maehara (2019) 提出了一个关于图数据的假设——输入数据的特征信号包括低频信号与高频信号, 而低频信号包含着对任务学习更加有效的信息.

与此同时, GCN 也存在一定的问题. 在使用多层 GCN 之后, 节点的区分性变得越来越差, 节点的表示向量趋于一致, 这使得相应的学习任务变得更加困难. 我们将这个现象称为多层 GCN 的过平滑问题.

GCN 相当于对输入信号做了一个低通滤波的操作, 这会使信号变得更加平滑, 这也是 GCN 模型的一个内在优势. 但是, 过犹不及, 多次执行这类对信号不断平滑的操作之后, 信号会越来越趋同, 也就丧失了节点特征的多样性.

GCN 过平滑问题的本质是信息传播次数过多, 导致节点特征趋同, 使得模型的区分能力下降. 数学上, 这可以归因于归一化邻接矩阵的特征值收敛.

$$H^{(l+1)} = \sigma \left(\tilde{A} H^{(l)} W^{(l)} \right) \quad (2.21)$$

$$H^{(L)} = \left(\tilde{A} \right)^L H^{(0)} W^{(0)} \dots W^{(L-1)}. \quad (2.22)$$

如果 L 很大, 由于 $\tilde{A}$ 是归一化的, 它的最大特征值小于 1, 因此不断迭代后, 所有节点的特征都会趋于一个稳定的状态, 即所有节点的表示向量变得相似, 从而导致分类能力下降.

2.7 其他经典交通流量预测模型

本节将介绍经典交通流量预测模型, 本章所介绍的模型将作为下一章节的对比模型使用.

2.7.1 长短记忆神经网络

在使用 LSTM 模型 (Greff, Srivastava, Koutník et al., 2016) 预测交通流量时, 虽然 LSTM 主要专注于学习时间依赖性, 但其网络结构中的层次结构也能够一定程度上捕捉到节点间的关系. LSTM 的每一层都有多个权重参数, 这些参数不仅用于学习时间序列中的依赖性, 还能通过全连接层的线性组合, 捕捉到不同时间步输入之间的相关性. 通过这些线性组合, LSTM 能够有效地“学习”到不同特征之间的复杂关系, 这种特性在某些情况下可以间接地反映出交通流量节点之间的潜在关联.

RNN 是一种基础的循环神经网络, 通过循环连接将前一时刻的输出传递给当前时刻, 用于捕捉序列中的时间依赖性. 然而, RNN 存在“梯度消失”问题, 导致它在处理长序列时, 无法有效记住远距离的信息. LSTM 是对 RNN 的一种改进, 设计了“门”机制来控制信息的传递. LSTM 通过引入输入门、遗忘门和输出门, 能够选择性地保存和忘记信息, 从而有效解决了梯度消失问题, 能够捕捉长期依赖关系. 相较于普通的 RNN, LSTM 能够更好地处理长时间间隔的依赖性, 尤其在自然语言处理和语音识别等任务中表现更好. 图 2.3 为 LSTM 的模型结构图.

序列的每一个位置, 输入是当前时刻的 x_t , 以及信息流中前一时刻的隐藏状态 h_{t-1} 和单元状态 c_{t-1} , 输出是当前时刻的隐藏状态 h_t 与单元状态 c_t .

LSTM 包含三个主要的门: 遗忘门 f_t 、输入门 i_t 、输出门 o_t , 以及单元候选状态 $\tilde{c}_t$;

遗忘门 f_t 决定了前一时刻的单元状态 c_{t-1} 有多少比例被遗忘.

$$f_t = \sigma \left(W_f x_t + U_f h_{t-1} + b_f \right). \quad (2.23)$$




图 2.3 LSTM 模型结构图

输入门决定了当前输入 x_t 和前一时刻的隐藏状态 h_{t-1} 对单元状态的影响.

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i). \quad (2.24)$$

候选单元状态是当前时刻的潜在记忆更新.

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c). \quad (2.25)$$

当前的单元状态是由遗忘门调节的上一时刻的状态 c_{t-1} 和输入门调节的候选状态 $\tilde{c}_t$ 加权合成的.

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t. \quad (2.26)$$

当前的隐藏状态是通过输出门调节的单元状态 c_t 的非线性变换. 输出门决定了从当前单元状态 c_t 中输出多少信息到隐藏状态中.

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (2.27)$$

$$h_t = o_t \odot \tanh(c_t). \quad (2.28)$$

因此, 可以将 LSTM 神经网络模块中用于处理 t 位置的式总结为:

$$c_t, h_t = \text{LSTM}(x_t, c_{t-1}, h_{t-1}). \quad (2.29)$$

LSTM 层的输出通常包括每个时间步的隐状态和单元状态. 在进行最终预测时, 可以根据任务的不同, 选取不同的输出方式. 对于序列标注任务, 可以使用最后一个

时间步的隐状态作为整个序列的表示进行预测; 对于序列生成任务, 则可以逐步使用 LSTM 的输出生成下一步的结果. 通过此机制, 使得模型能够在交通流预测中有效地利用过去的状态来预测未来的交通状况 (刘建伟和宋妍, 2022). 此外, LSTM 的输出还可以通过全连接层或其他网络层进一步处理, 映射到所需的预测维度, 例如分类或回归任务的输出. 这些输出通常经过 softmax 等激活函数, 转化为最终的预测结果.

2.7.2 图嵌入方法

图嵌入的主要目标是将图中每个节点映射到一个低维向量空间, 从而在嵌入空间中有效保留图的结构信息. 这些低维向量表示通常被称为节点嵌入, 能够反映图中节点的某些关键信息. 对于哪些信息应当被保留, 已有研究探讨了多种信息类型的保留方式, 包括节点的邻域结构信息、节点的结构角色、社区信息以及节点的状态特征等. 至于如何有效地保留这些信息, 近年来提出的多种技术方案对如何保留这些信息做出了回应. 尽管具体实现细节各异, 但大多数方法的共同理念是利用嵌入空间中的节点表示来重建原图中的关键信息. 其主要动因在于, 理想的节点嵌入应具备有效重建目标信息的能力. 当一些节点在随机游走过程中经常共同出现时, 这些节点被认为是相似的. 为了捕捉这种相似性, 通常会优化一个映射函数, 使得学到的节点表示能够有效重构从随机游走中提取的节点间共现信息. DeepWalk (Perozzi, Al-Rfou and Skiena, 2014) 是一种经典的图嵌入算法, 用于保留节点间的共现关系. 本节首先概述了 DeepWalk 算法的整体框架, 并详细阐述了其映射函数、特征提取器、重构器以及目标函数. 随后, 将介绍本文重点使用的保留节点共现关系的算法——node2vec. 定义映射函数 $f(v_i)$ 最简洁、方便的方式即使用查找表, 即 $f(v_i) = u_i = W^T e_i$.

设 $G = \{V, E\}$ 表示一个连通图. 考虑从图 G 上的节点 $v(0) \in V$ 开始的随机游走. 假设在随机游走的第 t 步访问的是节点 $v(t)$, 那么随机游走的下一个节点按照如下概率从 $v(t)$ 的邻居节点中选出:

$$p(v(t+1) | v(t)) = \begin{cases} 1/d(v(t)), & v(t+1) \in N(v(t)) \\ 0, & \text{其他} \end{cases} \quad (2.30)$$

两个节点间的共现被标示为元组 (v_{con}, v_{cen}) , 其中 v_{con} 表示上下文节点, v_{cen} 表示中心节点.

为了生成随机游走能够捕获整个图的信息, 每个节点都被用作起始节点生成 γ 个随机游走. 因此, 在遍历整个图后, 总共会获得 $|V| \cdot \gamma$ 个随机游走. 对于每个随机游走, 遍历其中的节点, 并将所有的 (v^{i-j}, v^i) 和 (v^{i+j}, v^i) 添加到共现列表 I 中.

通俗来说, 节点嵌入的主要思想即为: 两个节点在共现列表 I 中出现越多, 说明两个节点的关系约密切, 节点的结构信息越相像, 二者嵌入生成的向量在对方的嵌入向量方向上的投影越大. 在这里引入节点扮演不同角色时的不同向量表示: 中心节点与上下文节点, 即 $f_{cen}(v_i) = u_i = W_{cen}^T e_i$, $f_{con}(v_i) = v_i = W_{con}^T e_i$.

两个节点的共现关系可以表述为: 在中心节点 A 的上下文中观测到了 B . 故对全部的共现关系 I 进行概率建模:

$$p(v_{con} | v_{cen}) = \frac{\exp(f_{con}(v_{con})^T f_{cen}(v_{cen}))}{\sum_{v \in V} \exp(f_{con}(v)^T f_{cen}(v_{cen}))}. \quad (2.31)$$

一个被良好重构向量表示是能够准确地推断出 I 的共现信息的. 为了实现这一目标, 应该为从 I 中提取的元组输出高的概率值, 该思想类似于极大似然估计的思想, 选择那些使得已观察到的数据在给定模型下出现的概率最大的参数值. 随机游走假设共现 I 中的这些元组是相互独立的. 因此, 重构 I' 的概率可以建模如下, 使得下式的取最大:

$$I' = \prod_{((v_{con}, v_{cen}) \in I)} p(v_{con} | v_{cen}). \quad (2.32)$$

`node2vec` 引入了一种更灵活的方式生成随机游走, 它通过有偏的随机游走探索给定节点的邻域, 并用它代替 `DeepWalk` 中的随机游走来生成工. 具体地说, `node2vec` 提出了具有两个超参数 p 和 q 的二阶随机游走, 其定义如下.

$$a(v(t+1) | v(t-1), v(t)) = \begin{cases} 1/p \text{ dis}(v(t-1), v(t+1)) = 0 \\ 1 \text{ dis}(v(t-1), v(t+1)) = 1 \\ 1/q \text{ dis}(v(t-1), v(t+1)) = 2 \end{cases}. \quad (2.33)$$

该算法由 Grover and Leskovec (2016) 提出. `Node2Vec` 通过参数化的随机游走策略来调整节点之间的关系. 具体来说, `Node2Vec` 通过两个参数 p 和 q 控制随机游走的转移概率, 决定了在游走中如何平衡局部和全局结构:

参数 p 控制从当前节点返回到上一节点的概率. 较小的 p 值会增加返回到上一节点的概率, 进而使得游走更加局部化, 专注于节点的局部邻域. 参数 q 控制游走是否偏向于访问远离当前节点的节点. 较小的 q 值会导致游走更加探索邻近节点, 类似于 `BFS` (广度优先搜索); 较大的 q 值会使游走偏向于访问较远的节点, 类似于 `DFS` (深度优先搜索). 这种灵活的随机游走策略允许算法能够同时捕捉到局部邻域和全局结构特征.

由于城市数据（例如交通条件）的演变受到底层道路网的限制, 因此将道路网信息纳入预测模型至关重要. 为此, 相关文献提出了一种空间嵌入来将顶点编码为向量, 以保留图的结构信息. 顶点特征的学习过程通过 node2vec 方法实现. 要将预学习所得向量与整体模型进行协同训练, 则需将这些向量输入至包含两个全连接层的神经网络结构之中进行维度上的对齐, 最终形成空间嵌入. 表示为 $e_{v_i}^S \in \mathbb{R}^D$, 其中 $v_i \in v$.

Zheng et al. (2020) 进一步提出了一个时间嵌入, 以编码每个时间步长到一个向量. 将空间嵌入与时间嵌入进行维度上的对齐后, 融合为时空嵌入, 并联合节点特征, 使用转换注意力机制进行预测.

2.7.3 T - GCN

该模型由 Zhao, Song, Zhang et al. (2019) 在 DCRNN 模型的基础上, 提出一种基于 GCN 和 GRU 的时间图卷积网络模型, T-GCN 模型是为了解决交通预测问题而提出的一种新型深度学习框架. 该模型在传统的图卷积网络 (GCN) 基础上引入了时间序列的建模能力, 能够同时捕捉交通流数据中的时序变化和图结构的空间依赖关系.

在门控递归单元与图卷积网络相融合的基础上, 构建了 T-GCN 模型架构. 空间依赖性的建模, 是通过图卷积网络捕获路网拓扑结构完成的. 交通数据时间维度上的动态变化特征, 则使用门控递归单元进行学习.

具体而言, 即每个时间片段中单独使用 GCN 学习结合网络拓扑结构后的表示, 然后再将这些表示作为时序数据输入到循环神经网络中, 通过单元间的信息传递获得动态变化, 捕捉时间特征. 最后, 通过全连通层得到结果. 模型结构图如图 2.4 所示.




图 2.4 T-GCN 模型结构图 (胡晓荣, 2023)

第3章 基于注意力机制与图神经网络的交通流量预测

3.1 引言

尽管基于深度卷积神经网络的交通流预测算法在近年来取得了显著的成果,尤其是图神经网络 (GNN) 的引入,图神经网络在处理路网拓扑结构时具有明显优势,能够有效捕捉节点间的复杂依赖关系,极大增强了模拟交通数据空间特征的能力。但是现有算法在对交通流量行为的非线性变换特征进行学习时仍显不足,尤其是在捕捉数据时空特性方面。随着路网结构的不断扩展,复杂的道路布局对模型提出了更高的要求。虽然图神经网络能够较好地适应这些拓扑结构,并结合递归网络或时间卷积网络来有效学习时间维度的特征,预测效果有所提高,但仍有一些问题亟待解决。

(1) 递归网络或时间卷积网络在处理长序列数据时常常遇到梯度消失或梯度爆炸的问题,这会导致训练过程中的不稳定性。特别是在深层网络中,这些问题变得尤为突出,模型在时间维度上的学习能力有限,从而影响了整体的预测效果。梯度消失或爆炸不仅使得网络难以有效更新权重,而且可能导致信息在传递过程中逐渐丧失,影响长期依赖关系的学习。

(2) 图神经网络虽然能够在空间维度上取得良好的预测效果,但在交通流预测的过程中,节点之间的流动性并非一成不变。在现有研究中,通常通过固定的顺序或权重来定义节点之间的信息传递方式,这种方法忽略了现实中路网节点间流量转移的概率差异。每个节点的流量转移能力可能受到多个因素的影响,比如道路类型、周围设施和天气等,如何更加精准地表达这些节点间的异质性,是未来研究的重要方向。

(3) 图卷积网络在处理交通流数据时,可能会遭遇过平滑问题。过平滑是指随着图卷积层数的加深,节点之间的信息过度融合,导致模型难以区分不同节点的特征,进而引发过拟合问题。特别是在深度图神经网络中,过平滑会使得节点的表示变得过于相似,从而影响模型的泛化能力,导致预测效果不如预期。因此,如何平衡图卷积层数与模型性能之间的关系,避免过平滑的发生,是当前图神经网络在交通流预测中的一个亟待解决的问题。

针对上述三个问题,论文使用基于时空注意力机制和图网络模型的交通流预测方法。算法基于图神经网络的交通流预测模型,设计了一种基于时间与空间注意力增强的图卷积交通流预测模型,序列的学习将不再使用循环神经网络,改为同时使用时间维度上的注意力机制与卷积操作,同时为了区分邻域节点对于中心节点的贡献程度,采用了图注意力机制对于连接节点的边赋予不同的权重,提高了预测任务的精度。




图 3.1 模型结构示意图 (Guo et al., 2019)

下文详细介绍本章模型的结构、原理和实验结果。

3.2 基于时空注意力机制与图网络结合的交通流量预测方法设计思路

算法旨在从交通流数据中更好地提取出数据的时空特征, 整个模型如图 3.1 所示. 模型主要分为两个部分: (1) 动态时空相关性信息捕获, 通过时空注意机制得以实现. 复杂空间的相关性信息由空间注意获取. 动态时间相关性, 则依赖于时间注意力机制在不同时间片段上的运用. 邻接矩阵的信息与空间注意力机制, 在图卷积层的卷积运算中融合. (2) 时空卷积, 使用图卷积来捕获空间模式, 并使用时间卷积来描述时间特征. 另外, 考虑到交通流量数据在每天的不同时间段, 每周的不同时间段都具有不同的变化特征, 故选取样本片段时, 将选取预测时间段最近片段、昨日同期片段和上周同期片段, 并对三个分量的输出进行加权融合, 得到动态预测结果.

针对上文中提到的问题, 模型在频域卷积的过程中加入了注意力机制, 具体添加方式为: 在每次图卷积之前加入图注意力层, 通过学习节点之间的相似性计算得到相似性矩阵, 再将节点相似性矩阵与图卷积核进行哈德玛乘积, 得到带有注意力信息的

图卷积核运算矩阵。再通过时间卷积学习时间特征,最后通过全连接层,输出所需预测的时间片段。在本文所主要使用的时空注意力机制-图卷积模型中,主要即堆叠 2 个时空块和 1 个全连接层组成。在每个时空块中都有一个时空注意模块和一个时空卷积模块。为了优化训练效率,本文中也采用了残差学习框架 (He et al., 2016)。

3.3 模型具体结构分析

3.3.1 时空注意力机制

交通流量预测问题本质上属于时间序列预测范畴,需要依赖历史时段数据对未来状态进行推断。特殊之处在于,研究对象具有显著区别于常规时间序列的特征。若仅采用序列到序列的预测方式,道路网络内在拓扑结构信息将难以被有效捕获。由此可见,采用图网络模型与空间注意力机制相结合的方法更为适宜,能够实现对道路空间关系的建模。现有研究中关于时间维度预测的处理方式,多数情况下可见循环神经网络或时序卷积网络的应用实例。本文使用的时间注意力机制及时间卷积可以解决上述循环时间网络所出现的一些问题。

在聚合邻居节点的过程中,基于注意力机制,图注意力网络被采用。由于针对不同邻居节点的权重差异性,图神经网络模型的表达能力因此获得显著提升。权重的动态调整过程呈现出明显的空间异质性格局。由此可见,注意力机制的引入使得节点间的信息传递效率产生了质的飞跃,特别是在处理异构图的场景下表现得尤为突出。注意力机制最初受到人类视觉聚焦方式的启发,能够让模型在处理信息时自动聚焦于重要部分,从而提高效率和准确性。类似于人类在视觉感知中会聚焦于某个区域,忽略其余部分,注意力机制通过为输入的各个部分分配不同的权重,使模型能够在复杂任务中自动关注关键信息。这一机制最早在自然语言处理领域中得到了广泛应用,尤其是在机器翻译和文本生成等任务中,帮助模型在不同的词语和句子之间建立起关联,从而改善理解与生成的效果。

在深度学习中,注意力机制通过计算输入信息的加权和,使得模型能够在特定的上下文中获取更多相关信息,特别是在长序列的任务中展现出显著优势。它不仅提高了模型的表达能力,也大大提升了计算效率,成为了图像处理、语音识别等多个领域的重要组成部分。Bahdanau, Cho and Bengio (2015) 也首次在 Seq2Seq 模型中提出注意力机制,注意力机制旨在解决 RNN 循环结构在处理长序列时会出现的信息丢失问题,通过优化序列之间的交互方式,增强了模型对长距离依赖关系的捕获能力。

注意力机制的数学表述如下:

在注意力机制中,Source (源) 通常指的是输入序列或特征。这些是模型根据其

重要性进行权重分配的对象。源可以是一个单词、特征向量或任何其他类型的输入数据。Query（查询）是模型在注意力机制中用来查找相关信息的部分。它通常是当前需要进行处理或预测的目标。比如，在机器翻译中，查询可能是当前要翻译的单词的上下文。在注意力机制中，每个源通常会与一个 Key 和一个 Value 相关联。Key 用于与查询进行匹配或计算相似度，而 Value 则包含了源的实际信息或特征。最终的注意力输出是根据 Key 的匹配度加权求和的 Value。Attention Value（注意力值）是通过将 Query 与各个 Key 进行比较（如计算相似度或匹配度），得到的每个 Source 的相关性分数。这些分数表明了模型在当前预测中应关注的源的程度。高分表示源对当前查询的贡献较大，低分表示贡献较小。注意力机制的定义如下：

$$\text{Attention}(\text{Query}, \text{Source}) = \sum \text{similarity}(\text{Query}, \text{Key}) \cdot \text{Value}.$$

在图注意力网络（Graph Attention Network, GAT）中，Source、Query、Attention Value 和 Key-Value 的作用与标准注意力机制相似，但它们应用于图结构数据。具体来说，Source 是图中每个节点的特征向量，表示节点的输入信息；Query 是当前节点的查询向量，用于与邻接节点的特征进行匹配，来决定哪些节点对当前节点的表示贡献较大；Key 是每个邻居节点的特征向量，用于与查询向量进行匹配，计算相似度；而 Value 是节点本身的特征信息，用于在计算加权平均时作为输出。因此，图注意力机制通过对每个节点的邻居节点进行加权聚合，来学习节点之间的关系和图的结构信息。

假设中心节点为 v_i ，我们设邻居节点 v_j 到 v_i 在某一层后的权重系数为：

$$e_{i,j} = a(Wh_i, Wh_j). \quad (3.1)$$

$W \in \mathbb{R}^{d(l+1) \times d(l)}$ 是对该层节点特征进行仿射变换的权重参数。 $a()$ 是计算两个节点相关度的函数。关于 a 的选择，可以灵活多样，输出节点之间的相似度即可。既可以选择对进行仿射变换后的节点特征进行内积运算，也可以通过网络层的再次嵌套。本文选择的方法为后者：

$$e_{i,j} = \text{Leaky ReLU}(a^T [Wh_i \parallel Wh_j]). \quad (3.2)$$

其权重参数 $a \in \mathbb{R}^{2 \times d(l+1)}$ ，激活函数设计为 $\text{LeakyReLU}()$ 。为了更好地分配权重，需要将与所有邻居计算出的相关度进行统一的归一化处理，具体形式为 softmax 归一化：

$$\alpha_{i,j} = \text{softmax}_j(e_{i,j}) = \frac{\exp(e_{i,j})}{\sum_{v_k \in N(v_i)} \exp(e_{i,k})}. \quad (3.3)$$

一旦完成上述权重系数的计算, 按照注意力机制加权求和的思路, 节点 v_i 新的特征向量为:

$$h'_i = \sigma \left(\sum_{v_j \in N(v_i)} \alpha_{i,j} W h_j \right). \quad (3.4)$$

关于空间的注意力机制计算如下:

$$S = V_s \cdot \sigma \left(\left(X_h^{(r-1)} W_1 \right) W_2 \left(W_3 X_h^{(r-1)} \right)^T + b_s \right) \quad (3.5)$$

$$S'_{i,j} = \frac{\exp(S_{i,j})}{\sum_{j=1}^N \exp(S_{i,j})}. \quad (3.6)$$

关于时间的注意力机制计算如下:

$$E = V_e \cdot \sigma \left(\left(X_h^{(r-1)} U_1 \right) U_2 \left(U_3 X_h^{(r-1)} \right)^T + b_e \right) \quad (3.7)$$

$$E'_{i,j} = \frac{\exp(E_{i,j})}{\sum_{j=1}^T \exp(E_{i,j})}, \quad (3.8)$$

其中 V_s 、 W_1 、 W_2 、 W_3 、 b_s 、 V_e 、 U_1 、 U_2 、 U_3 、 b_e 均为可学习的参数.

时空注意模块让网络自动地相对较多地关注有价值的信息. 从计算的层面来说, 将由时间注意机制调整的输出作为输入, 输入到空间卷积模块中. 具体来说, 为了动态调整节点之间的相关性, 对于图卷积运算, 将图卷积参数矩阵 M 融合空间注意矩阵 $S_{i,j}$ 信息, 然后得到 $M \odot S'_{i,j}$. 时空卷积模块主要用来建模交通数据的时空依赖性. 时空卷积模块包括用于从原始的基于图的交通网络结构中捕获空间特征的图卷积, 以及用于描述来自附近的时间切片的时间切片上的时间卷积. 在空间维度上的图卷积操作捕获了每个节点的相邻信息后, 在时间维度上进一步叠加标准卷积层, 通过合并相邻时间片上的信息来更新节点的信号, 最后通过全连接层连接输出预测信号.

3.3.2 图滤波器优化

最后, 提出关于图卷积层中图滤波器的优化. 图谱滤波的思想是调制图信号的频率, 使得其中一些频率分量被保留或放大, 而另一些频率分量被移除或减小. 因此, 给

定一个图信号, 首先需要对其进行图傅里叶变换, 以获得它的图傅里叶系数, 然后对这些系数进行调制, 再在图域中重构该信号.

根据第二章图基础理论介绍, 图傅里叶变换被定义为:

$$\hat{f} = U^T f, \quad (3.9)$$

由信号 f 所进行的图傅里叶变换操作中, 其生成系数可由 $\hat{f}$ 表示. 对于图信号 f 而言, 各个图傅里叶分量所具有的贡献度, 正是通过这些傅里叶系数得以体现. 对应于第 i 个图傅里叶分量 u_i 的, 是 $\hat{f}$ 当中第 i 个元素的特定存在. 实例表明, 当需要对图信号 f 的频率特性实施调制时, 可采取对图傅里叶系数执行滤波处理的方式. 以频率 λ_i 作为输入变量的函数 $\gamma(\lambda_i)$, 其具体形式决定了相应频率分量将被如何调制.

$$\hat{f}' = \hat{f}[i] * \gamma(\lambda_i), i = 1, 2 \dots N. \quad (3.10)$$

矩阵形式表示如下:

$$\hat{f}' = \gamma(\Lambda) * \hat{f} = \gamma(\Lambda) U^T f. \quad (3.11)$$

有了滤波系数之后, 就可以将图信号重新构建到图域:

$$f' = U \hat{f}' = U * \gamma(\Lambda) U^T f. \quad (3.12)$$

滤波过程可视为将算子 $U * \gamma(\Lambda) U^T$ 应用于输入的图信号. $\gamma(\Lambda)$ 控制着图信号 f 的每个频率分量的滤波过程. 例如, 如果 $\gamma(\lambda_i)$ 等于 0, 即 $\hat{f}[i] = 0$, 则频率分量 u_i 会从图信号中移除. 如果知道该如何调制输入信号中的频率, 那么就可以用相应的方式设计函数 $\gamma(\Lambda)$. 然而, 在实际使用中, 当把基于谱的滤波器作为图滤波器时, 哪些频率更重要往往是未知的. 因此, 就像传统的神经网络一样, 可以通过数据驱动的方式学习合适的图滤波器. 具体来说, 可以用某些函数对 $\gamma(\Lambda)$ 建模, 然后在数据的监督下学习参数. 一种自然的尝试是在设计 $\gamma(\cdot)$ 时给予它充分的自由. 具体而言, 函数 $\gamma(\cdot)$ 定义为:

$$\gamma(\lambda_i) = \begin{bmatrix} \theta_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \theta_N \end{bmatrix}. \quad (3.13)$$

此类非参数化卷积算子具有显著的局限性. 节点数 N 与需学习参数数量相等, 当 N 取值较大时, 内存占用量将显著提升, 数据拟合需求亦随之增加. 稠密矩阵特性可能存在于卷积算子 $U * \gamma(\Lambda) U^T$ 中, 因此输出信号 f' 的第 i 个元素计算过程可

能涉及图中全部节点. 拉普拉斯矩阵特征分解的包含于该算子计算过程中, 加之稠密矩阵相乘运算的存在, 计算代价高昂.

Poly-filter (Han, Du, Sun et al., 2021) 旨在解决谱滤波问题. 谱滤波在 GNN 中至关重要, 它使得模型能够有效地处理图结构数据, 从而更好地学习节点和边的表示. Poly-filter 特别设计用于通过应用多项式滤波器来平滑图信号的谱响应. 这一方法建立在谱卷积框架的基础上, 其中图拉普拉斯算子在定义图结构中起着核心作用. 通过使用多项式滤波器, Poly-filter 能够更高效地处理图数据, 避免了通常在谱方法中需要进行昂贵的特征值分解.

然而, Poly-filter 也存在一些局限性. 其主要挑战之一是滤波器的频率响应在大图或者多项式度数较高时可能会不稳定. 多项式的度数直接影响滤波器捕捉图中长程依赖的能力, 但也增加了过度平滑的风险, 即模型可能失去准确预测所需的细粒度信息. 此外, 主要问题在于多项式基 (如 $1, x, x^2, \dots$), 这些系数间存在相互依赖性, 学习过程中的扰动易引发不稳定性. 一个系数的更新行为可能导致其余系数发生改变, 由此可见基函数正交化的重要性.

为了解决这些问题, Defferrard, Bresson and Vandergheynst (2016) 提出了 Cheby-Filter 作为替代方案. Cheby-Filter 提供了一种减少过度平滑和计算复杂度的解决方案. 它们利用 Chebyshev 多项式, 能够高效地近似图卷积, 而无需显式地计算图拉普拉斯算子的特征值. Cheby-Filter 还提供了更好的控制, 能够稳定地处理图的不同大小. 由于它们能够以较少的计算资源处理长程依赖, 因此在大规模图学习任务中, Cheby-Filter 被认为是 Poly-filter 的一个有前景的替代方案.

切比雪夫多项式可以由如下递推关系生成:

$$T_k(y) = 2yT_{k-1}(y) - T_{k-2}(y), \quad (3.14)$$

其中 $y \in [-1, 1]$, $T_0(y) = 1$, $T_1(y) = y$. 切比雪夫多项式彼此正交, 由于切比雪夫多项式的定义域是 $[-1, 1]$, 为了利用切比雪夫多项式近似卷积算子, 需要重新缩放并平移拉普拉斯矩阵的特征值, 具体如下:

$$\tilde{\lambda}_l = \frac{2 * \lambda_l}{\lambda_{\max}} - 1. \quad (3.15)$$

因此, y 为矩阵时即为:

$$\tilde{L} = \frac{2L}{\lambda_{\max}} - I. \quad (3.16)$$

3.4 实验结果分析

本节对于上文提出的基于时空注意力机制-图网络交通流预测模型进行实验分析验证。实验在多个数据集上展开, 包括 METR-LA 和 SZ 数据集, 下文将详细介绍。实验主要包含: 由模型和其他主流预测模型的横向对比结果, 以及模型各部分模块的消融实验对比。

3.4.1 实验细节设置

本文基于 pytorch 框架实现了时空注意力机制-图卷积模型. Kipf and Welling (2016) 等检验了切比雪夫多项式 $K \in \{1, 2, 3\}$ 的项的个数。但随着 K 的增大, 预测性能提高的效率微乎其微。考虑到计算效率和预测性能的提高程度, 将 K 设置为 3 以及沿时间维度的卷积核大小设置为 3。在模型训练之前, 需要对原始数据集进行预处理。根据传感器的地址信息与连通属性构建路网的图结构表示形式, 即构建邻接矩阵。为了捕捉交通流量的近期特征、日周期特征以及周周期特征, 这里选择了一个包含 36/12 个时间戳的时间窗口作为预测输入。(LA 数据集为 36 个时间点, SZ 数据集为 12 个时间点) 具体来说, 输入包括: 前一个小时的流量数据、前一日相同时间段的流量数据, 以及前一周相同时间段的流量数据。通过这种方式, 模型能够学习到交通流量在不同时间尺度下的变化模式。数据输出为预测未来一小时的交通节点的流量 (LA 数据集为 12 个时间点, SZ 数据集为 4 个时间点)。在本章的实验中, 每个 Batch 设置大小为 32, 共 100 个 epoch。网络模块中时空注意力机制的相关映射维度为 64 维。所有的时间卷积层都使用 64 个卷积核。为方便对齐, 图卷积的输出维度也设置为 64 维。训练过程中, 初始学习率设置为 0.01, 使用 Adam 进行优化器进行训练, 每个 epoch 都对训练模型进行验证。将选择验证集损失最小时对应的模型参数, 作为最终模型参数, 用于在测试集上进行预测。按照 6 : 2 : 2 的比例划分为训练集、验证集和测试集。

本文将主要围绕下列 2 个数据集展开实验:

(1) METR_LA (Metro Los Angeles): 数据集是一个由加利福尼亚大学洛杉矶分校 (UCLA) 发布的交通流量数据集, 专门用于时间序列预测和交通流量预测任务。这个数据集为研究交通预测、时间序列分析、深度学习方法等领域提供了一个非常重要的基准。METR_LA 数据集中的数据来源于洛杉矶地区的高速公路网络, 记录了在不同地点的交通流量信息。具体来说, 它包含了从 207 个传感器收集到的从 2012/03/01-2012/06/27 (约 34272 条记录) 的数据。这些传感器监测了汽车的流量、速度、占用率等信息, 且数据以时间序列的方式进行记录。这里使用行驶速度作为预测的变量, 行驶速度基本能反映交通拥堵情况。

(2) SZ 数据集: SZ-taxi 数据集是从深圳市的出租车运行数据系统采集而来, 在 T-GCN 网络中首次使用. 数据集主要采集地区在罗湖区, 数据类型是出租车的行驶速度. 数据集的时间跨度为 2015 年 1 月 1 日到 2015 年 2 月 4 日, 相邻两个采样之间间隔 15 分钟. 数据集内部包括了 156 个道路节点在不同时刻的速度值, 以及代表节点之间连接情况的邻接矩阵.

另外, 这两个数据集也有不同的特点: SZ 数据集是在城市道路高度复杂化的区域采集而成, 其受到的外部因素的影响程度高于 LA 高速公路数据集.

3.4.2 实验结果

预测结果选择 RMSE(均方根误差)、MAE(平均绝对误差)、和 MAPE(平均绝对百分比误差) 作为最终的评估指标. 最终各模型预测结果见下表.

RMSE 是预测值与实际值之间误差的平方的均值的平方根, 公式为:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3.17)$$

RMSE 对较大误差赋予更高的权重, 因为误差被平方后放大了, 因此它在处理具有较大异常值的情况时更加敏感. 它通常用于强调对大误差的惩罚, 适用于对极端误差非常敏感的情形.

MAE 是预测值与实际值之间绝对误差的平均值, 公式为:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (3.18)$$

MAE 反映了预测值偏离实际值的程度, 越小表示模型越准确. 它不考虑误差的方向, 仅关心误差的大小, 因此适用于需要量化误差大小的情境.

MAPE 是误差的绝对值与实际值之比的平均值, 公式为:

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|. \quad (3.19)$$

MAPE 提供了一个百分比误差, 能够衡量预测的相对精度. 由于它基于实际值与预测值的比例, 通常用于评估预测值在不同数量级的实际数据下的相对误差. 然而, 如果实际值接近零, MAPE 会表现出较大的误差, 这在某些情形下可能导致不准确的评估.

为了验证本文提出的时空注意机制的优势, 使用了一些基线模型, 长短记忆神经网络、图嵌入技术、TGCN 模型等进行对比, 以展示其先进性. 还设计了相关退化版

本的模型, 分别为时空注意力模型（相关参数相同, 但不使用图卷积来学习节点间的相关性）, 时间注意力-图卷积模型（不使用图注意力机制）, 以验证图注意力机制能缓解图卷积过平滑的问题.

由实验结果（见表 3.1 和表 3.2）可知, 本文主要使用的时空注意力机制-图卷积模型（下列简称 ASTGCN 模型）, 预测精度较基线模型都有一定程度的提升. ASTGCN 在 LA 数据集上 MAE 和 RMSE 分别较对比模型下降至少 40.70% 和 33.08%. 在 SZ 数据集上 MAE 和 RMSE 分别较对比模型下降至少 17.22% 和 11.76%.

表 3.1 SZ 数据集实验结果

SZ 数据集	RMSE	MAE	MAPE
T-GCN	4.59	3.31	42.97%
AST-GCN	4.05	2.74	9.21%
Graph_Embedding	23.47	13.69	13.50%
LSTM	11.84	5.31	21.92%

表 3.2 LA 数据集实验结果

LA 数据集	RMSE	MAE	MAPE
T-GCN	12.57	8.3	290.61%
AST-GCN	6.94	3.57	10.22%
Graph_Embedding	31.49	17.28	47.00%
LSTM	10.37	6.02	301.53%

使用传统的 LSTM 模型时, MAPE 较高, 说明该模型未能充分捕捉到即将发生拥堵的路口信息. LSTM 主要关注时间序列数据的时间依赖性, 但在处理交通流量预测时, 缺乏对空间信息和路网中节点间交互的有效建模. 交通流量不仅是时间序列的动态变化, 还受到路网结构和相邻路口流量的影响, 因此 LSTM 的空间建模能力较弱, 无法及时捕捉到不同路口之间的复杂依赖关系, 从而影响了拥堵情况的准确预测.

图嵌入模型在预测任务中的表现较差, 可能的原因在于它们通过预先学习的低维嵌入来表示节点或图结构, 这些嵌入虽然能够捕捉一定的结构信息, 但通常无法直接针对具体的下游任务进行优化. 因此, 图嵌入在转化为具体任务时, 其学习到的表

示可能对预测并不起作用, 缺乏足够的任务相关性. 而与之相比, 图卷积网络采用端对端的学习方式, 能够在训练过程中自动调整图结构的表示, 从而更好地适应任务需求. GCN 通过消息传递机制动态更新节点特征, 并能够逐层学习更加精细的局部和全局图信息, 因此其在捕捉节点间复杂关系和结构依赖方面更为有效, 通常能取得更好的预测性能.

使用 T-GCN 预测模型的指标均不及本章节中的时刻注意力机制-图网络模型, 二者模型主要区别在, 前者使用循环神经网络学习序列特征, 后者使用时间注意力机制联合时间卷积学习序列特征. T-GCN 在 SZ 数据集上的实际值与预测值比较, T-GCN 对交通流量的升降趋势预测有一定的延迟, T-GCN 模型无法即使预测出即将发生堵塞的节点. 图 3.2 展示了 T-GCN 与本文使用的 ASTGCN 模型在 SZ 数据集测试集部分的预测效果, 本文的模型基本能够拟合真实交通流量, 而 T-GCN 在验证集预测上几乎失效.

图 3.3 展示了 T-GCN 与 ASTGCN 在 LA 数据集的预测精度对比, 可见 ASTGCN 在 LA 数据集上表现比 SZ 数据集更好, 更能预测出那些即将发生拥堵的交通节点. 因此, ASTGCN 模型更适用于受外部因素干预较小的交通网络数据.

消融实验相关结果 (见表 3.3 和表 3.4) 证明, 模型中一些模块的优化能够提升模型精度.

表 3.3 SZ 数据集消融实验结果

SZ 数据集	RMSE	MAE	MAPE
AST-GCN	4.05	2.74	9.21%
w/o SpatialAttention	4.07	2.80	8.46%
w/o GCN	3.99	2.77	7.65%

表 3.4 LA 数据集消融实验结果

LA 数据集	RMSE	MAE	MAPE
AST-GCN	6.94	3.57	10.22%
w/o SpatialAttention	7.37	4.03	11.34%
w/o GCN	6.87	3.82	12.86%

ASTGCN 模型比仅使用时间注意力机制的模型在 LA 数据集表现最好, MAE 下




图 3.2 T - GCN 与 ASTGCN 在 SZ 测试集上预测效果对比




图 3.3 T - GCN 与 ASTGCN 在 LA 测试集上预测效果对比

降 11.41%, RMSE 下降 5.83%。这一提升主要归因于空间注意力机制的引入,有效缓解了图卷积网络中的过平滑问题。空间注意力机制能够动态调整节点间的相互关系,使得信息传播更加精细化,避免了信息过度平滑,从而改善了模型的表达能力和预测精度,尤其在处理图数据时,能够捕捉到更加局部且重要的特征。

在本章节中,我们展示的算法在部分数据集上的结果表现逊色于消融 GCN 的退化模型。这一现象的背后原因,可能与 GCN 中预先定义的图结构不完全适用于特定问题相关。传统的 GCN 方法通常依赖于固定的图结构,该结构是在训练开始前就已经确定。然而,许多实际问题中,图结构并非固定,而是具有一定的动态性或者应根据数据本身的特征来进行调整。例如, GWnet (Wu and He, 2019) 就采用了非固定结构的图网络,这使得其能够在数据集的图结构变化时灵活地进行调整,从而可能获得更好的性能表现。本文将在后续部分,探索如何改进 GCN 方法,通过引入更加灵活和动态的图结构,以提升模型在不同任务中的适应性和表现。

3.4.3 多信息融合适应性

现有的交通流研究主要依赖于数据集中的传感器数据,预测模型通过历史交通数据来预测未来的流量。然而,交通流量数据具有非线性特征,导致其未来状态不仅仅与历史数据相关,还会受到其他外部因素的影响,比如道路类型、周边设施的种类以及天气条件等 (Zhang, Zheng, Sun et al., 2019)。因此,如何将这些外部信息整合到预测模型中,并以合适的方式将其加入模型,是一个值得进一步探讨的课题。因此,本部

分内容将论述时空注意力机制-图网络模型对于融合多信息特征的适应性。

外部信息源主要有两部分, 静态信息例如 POI (道路兴趣点指数), 通常指的是在特定区域内具有某种吸引力或重要性的地理位置。这些地点可能是旅游景点、商店、餐馆、医院、学校等。POI 数据广泛应用于地图服务、地理信息系统 (GIS)、推荐系统等领域, 可以帮助分析和理解人们的活动模式、行为趋势等。POI 信息与交通流数据结合在一起, 可以为交通流预测、城市规划、推荐系统等应用提供有价值的辅助数据。通过分析 POI 数据与交通流之间的关系, 研究人员能够更好地理解交通模式以及外部因素对交通流的影响。动态信息内容随着时间的改变而改变。在多个动态信息中, 本文选取了天气信息作为外源特征。其他还包括道路占有率、车辆数等。

现有研究融合多信息的思路为直接将外源信息于原始信息拼接 (胡晓荣, 2023)。而在本文中, 网络层的主要设计思路为, 在通过时空注意力层、时空卷积的所有运算后, 融合外部信息, 将外部信息进行仿射变换与交通序列的维度进行对齐后直接将两者相加。具体运算如下式展示, 其中 $F \in \mathbb{R}^{B*N*out}$ 为时空注意力层、时空卷积层的输出, out 为输出通道数 (根据上文为 64), $I \in \mathbb{R}^{B*N*in}$ 为外部信息, in 为输入外部信息通道数 (SZ 为 2, 融合天气和 POI 信息, LA 为 1, 融合道路占有率指标)。 $W \in \mathbb{R}^{in*out}$ 。

$$H = F + I * W. \quad (3.20)$$

另外通过引入外源信息, 能够有效地增强模型对时间和空间注意力矩阵的学习能力。多信息融合反映了更多节点的信息, 有利于增强模型对节点的相似性学习。

SZ-taxi 数据集在后续的研究中收集了额外的补充了道路节点的 POI 属性和 31 天中的天气状况, 得到本研究最终的数据集。图 3.4 展示了晴天和雨天, 随机选择一些节点的行车速度均值, 可以发现晴天和雨天的速度会有明显差异。

实验结果如表 3.5 所示, 该结果可以论证, 时空注意力机制-图网络也可以拓展到多信息融合, 另外融合多信息可以在一定程度上提高预测精度, LA 数据集在融合进道路占有率指标后 (道路上被占用的车辆或其他交通参与者数量与道路总容量的比值), RMSE 下降 3.47%。因此, 什么样的信息将有助于流量预测, 如何更加有效利用外源信息, 并将其更好融合进模型, 也是未来研究的方向。




图 3.4 不同天气状况下速度对比

表 3.5 融合多信息与原始数据预测结果

	RMSE	MAE	MAPE
SZ with Weather & POI	4.02	2.71	9.21%
SZ	4.05	2.77	9.21%
LA with Occupancy Rate	6.92	3.64	10.85%
LA	7.17	3.67	11.84%

第4章 基于时空注意力机制-自适应图网络的交通流量预测方法

4.1 引言

本文在上一章中介绍了一种基于时空注意力机制和图注意力网络的交通流预测的方法。在上一章的模型中, 研究使用了图网络和空间注意力机制来构建道路中的空间相关性, 使用了时间注意力机制来学习序列的时间相关性。虽然上一章的模型在交通流预测任务中, 通过融合注意力机制和优化网络结构取得了不错的成绩, 但是 GraphWavenet (Wu et al., 2019) 和 AGCRN 这一类网络在 METR-LA 和 PEMS-BAY 数据集上的实验结果表现, 这类模型所设计的动态变化邻接矩阵在预测效果中有着较大的正向作用。另外, 上一章节的部分消融模型(仅使用时空注意力机制, 不使用图卷积的模型)在 SZ 数据集上的精度较原始模型略高, 也说明了根据预先定义的邻接矩阵进行图卷积的运算, 在某些数据集的效率并不高。

目前主流交通流预测任务的都是基于图神经网络的时空网络模型进行预测。虽然各种基于图网络进行改进的模型已经在预测任务上取得了不错的效果, 但是这些模型仍存在以下问题:

(1) 上述模型图卷积的部分, 从网络设计中可以看出所有节点参数的共享模式, 共享参数尽管能够降低参数量级并提取跨节点共性模式, 但对于某些特定任务而言并非最优解。当前主流方法在精细化捕捉数据源特异性模式方面表现欠佳, 这种现象源于参数共享策略的固有缺陷。交通流量序列本身具有多样化特征, 不同数据源属性差异导致其模式呈现显著异质性甚至相互矛盾。由此可见, 仅依赖共享模式提取难以满足预测精度要求。必须为每个独立节点配置专属参数集, 节点特定模式的学习任务才能得以实现。

(2) 当前研究中, 采用图卷积网络(GCN)的技术方案普遍存在着前置性约束条件。预先构建相互连接的图结构, 该结构需借助相似度或距离度量的计算方式得以实现, 其目的在于空间相关性特征的捕捉。这一过程不仅需要投入大量专业领域知识储备, 更表现出对图结构质量的高度敏感性特征。由此可见, 通过此类方法所生成的图结构往往呈现出直观性强但完整性不足的显著特点, 且难以实现与预测任务需求间的直接适配性;(Han, Du, Sun et al., 2021)。另外, 所有的图卷积操作都需要定义卷积核, 现有的卷积核有两种主要的定义方式: 首先是基于图拉普拉斯矩阵的卷积核, 该方法基于图的拉普拉斯矩阵来计算卷积核, 通常涉及到对图的特征值分解。具体来

说, 图卷积操作通过拉普拉斯矩阵的特征向量来进行谱卷积. 这种方式能够捕捉到图的全局结构信息, 并且为每个节点计算特征的加权和. 然而, 这种方法的计算成本非常高, 尤其是在图特别大的情况下, 这将导致显著的资源消耗和时间延迟. 为了解决基于拉普拉斯矩阵方法的计算效率问题, 另一种方法是设计不依赖于拉普拉斯矩阵特征向量的卷积核. 在这种方法中, 卷积核需要通过巧妙设计来捕捉图的局部结构信息, 而不需要显式地计算图的谱分解. 这样的设计通常依赖于图的邻接矩阵、图的局部拓扑结构、邻居节点的权重等信息. 尽管这种方法在计算上更加高效, 但卷积核的设计通常需要丰富的领域知识和经验, 需要对图的结构有深入的理解, 并且可能涉及复杂的启发式搜索或者基于学习的优化方法.

因此本文针对上述问题提出了一种基于注意力机制和自适应图网络的交通流预测方法. 算法基于时空注意力机制-图神经网络的交通流预测研究, 提出了基于自适应图的图神经网络交通流预测模型, 以学习交通道路在空间中随着时间变化的连通属性.

4.2 自适应图的设计思路

为了解决图网络目前存在的上述两个问题, 本节将提出模型改进的设计思路. 自适应模块已经逐渐开始被应用于交通流量预测领域, FOGS 采用学习驱动的图结构, 使得模型可以动态调整不同道路节点间的关系, 提高预测的自适应性 (Rao, Wang, Zhang et al., 2022). **2021_Han_Dynamic_and_multi_faceted_spatio_temporal_deep_learning_for_traffic_flow_prediction** 也在模型框架中引入可学习的图结构, 利用历史数据自适应调整道路间的连接权重, 从而更精准地刻画道路间的动态影响. 本文的自适应模块主要包含两部分: 一个节点自适应参数学习 (NAPL) 模块, 用于捕获节点特定的模式; 以及一个数据自适应图生成 (DAGG) 模块, 以自动推断不同流量序列之间的相互依赖关系.

上一章的图的卷积运算思路, 主要基于下式 (展示为一层的图卷积运算):

$$H = \sigma(\theta XW), \quad (4.1)$$

其中 θ 是根据图拉普拉斯矩阵以及图滤波器理论设计的卷积核, $X \in \mathbb{R}^{N \times C}$, 其中 N 为节点数量, C 为输入通道数量. $H \in \mathbb{R}^{N \times F}$, 其中 F 为输出通道数量. $W \in \mathbb{R}^{C \times F}$, 是可学习的参数. 从一个节点 (如节点 i) 的角度来看, GCN 操作可以看作是将节点 $X_i \in \mathbb{R}^{1 \times C}$ 的特征转换为 $H_i \in \mathbb{R}^{1 \times F}$, 所有节点之间共享参数 W . 来自两个相邻节点的流量流也可能在某些特定的属性或是某些特定时期呈现不同的模式. 因此, 仅捕获所有节点之间的共享模式对于准确的流量预测是不够的.

但是, 为每个节点分配参数会导致 $W \in \mathbb{R}^{N \times C \times F}$, 参数量过大将导致计算成本的上升, 也会导致过拟合问题, 特别是当 N 很大时. 为解决该问题, 本文创新性地引入节点自适应参数学习模块化组件. 通过该模块与上一章模型有效整合, 参数学习过程不再直接针对高维权重矩阵 $W \in \mathbb{R}^{N \times C \times F}$ 进行优化操作, 转而采用两个低秩矩阵的协同学习机制: 1) 节点嵌入矩阵 $E_g \in \mathbb{R}^{N \times d}$, 其中 d 为嵌入维数, $d \ll N$; 通常可以选择 2. 2) 一个权重池 $W_g \in \mathbb{R}^{d \times C \times F}$. 然后, 可以通过 $W = E_g \cdot W_g$ 生成 W . 从一个节点 (例如, 节点 i) 的角度来看, 该过程根据节点嵌入的 E_{g_i} 从一个大型共享权重池 W_g 中提取参数 W_i , 这可以解释为从所有流量系列中发现的一组候选模式中学习出特定于节点的模式. 最后, 节点自适应参数学习增强的 GCN 可以公式化为:

$$H = \sigma(\theta X E_g \cdot W_g). \quad (4.2)$$

现存研究领域中, 基于图卷积网络 (GCN) 的交通流预测模型存在着显著缺陷性. 这类模型必须依赖预先定义的邻接矩阵 A 才能实施图的卷积运算操作. 传统研究通常采用距离函数或相似性度量的计算方式提前构建图结构, 但该方法难以捕捉节点间潜在的隐含关联性. 针对这一局限性, 本项研究工作创新性地设计出数据自适应的图生成机制, 该模块能够从原始数据中自主推导出隐藏的相互依赖关系. 具体实现过程中, 首先进行的是所有节点的随机初始化处理, 建立可学习的节点嵌入字典 $E_A \in \mathbb{R}^{N \times d_e}$, 其中 E_A 的每一行向量对应着特定节点的嵌入表示, d_e 则表征着节点嵌入的维度数量. 与基于节点相似度的传统构图方法相仿, 通过将 E_A 和 E_A^T 进行乘积运算, 可以推导出各节点对之间的空间依赖性关系. 在此过程中, 采用 softmax 函数对生成的自适应矩阵实施归一化处理. 区别于传统方法需要生成邻接矩阵 A 并计算拉普拉斯矩阵的操作流程, 本方案直接生成图卷积核 θ . 这种改进有效避免了迭代训练过程中冗余计算的产生. 随着训练过程的推进, E_A 将实现自动更新优化, 从而学习到不同交通流量序列间潜在的依赖模式, 最终形成适用于图卷积运算的自适应矩阵. 相较于人工设计的图卷积核函数, 这种自适应图生成机制展现出更简洁的结构特性, 降低计算复杂度的同时提升了模型的表征能力. 最后, 自适应图生成模块与节点自适应参数学习增强的 GCN 可以表述为:

$$H = \sigma(\text{softmax}(\text{RELU}(E_A \cdot E_A^T)) X E_g \cdot W_g). \quad (4.3)$$

因此, 将原网络层中的 GCN 替换为自适应图生成模块与节点自适应参数学习增强的 GCN, 生成时空注意力机制-自适应图网络.

4.3 实验结果分析

第 3 章使用了 METR-LA 数据集和 SZ-taxi 数据集, 本章依旧在这 2 个数据集上进行实验. 节点自适应参数学习中, E_g 的参数 d 设置为 2, E_A 的嵌入维度设置为 64, 即每个节点将学习一个 64 维度的节点表示. 其他实验参数设置如第 3 章介绍, 也不做赘述. 本部分研究将只对比时空注意力机制-自适应图网络与上一章节的时空注意力机制-自适应图网络模型, 研究依旧采取相同的评估标准.

表 4.1 自适应图网络与原模型对比

		RMSE	MAE	MAPE
SZ 数据集	时空注意力机制-图网络	4.05	2.74	9.21%
	时空注意力机制-自适应图网络	4.04	2.71	9.21%
LA 数据集	时空注意力机制-图网络	6.94	3.57	10.22%
	时空注意力机制-自适应图网络	6.34	3.03	9.06%

另外, 在此部分中, 还将对训练时间进行记录, 研究在二者模型误差较小的情况下, 模型的计算速度, 以便投入实际运用中节省计算资源. 主要记录了 100 个 epoch 中每训练 1000batch 数据时, 训练消耗的总时间.

在深圳数据集中, 加入自适应模块共需学习参数数量为 174702, 原始模型参数数量为 154110. 原始模型与改进模型的精度相差不大, 在训练时间上, 原始模型的训练速度比改进后模型的训练速度低 34.76% 以上. 在 LA 数据集中, 加入自适应模块共需学习参数数量为 289703, 原始模型参数数量为 262379. 但模型的训练时间, 加入自适应模块训练耗时 5.84h, 原始模型耗时 9.81h, 计算速度提高了 40.47%. LA 数据集在 MAE 指标也得到 15.12% 下降.

表 4.2 自适应图网络与原模型训练时间对比

		时空注意力机制- 图网络	时空注意力机制- 自适应图网络
SZ 数据集	SZ1000steps	35.40s	30.58s
	SZ2000steps	69.57s	60.13s
	SZ3000steps	108.56s	91.21s
	SZ4000steps	210.90s	137.89s
	...	...	...
LA 数据集	LA1000steps	461.93s	413.49s
	LA2000steps	1021.12s	846.13s
	LA3000steps	1497.50s	1196.48s
	...	...	...
	LA_All_steps	9.81h	5.84h

第 5 章 总结与展望

5.1 总结

本文综述了图神经网络 (GNN) 的发展历程和应用, 重点讨论了从图拉普拉斯矩阵到图滤波器再到图卷积的演化过程, 阐述了这些方法在学习空间结构方面的重要性. 图神经网络通过在图结构上进行有效的信息传递, 能够捕捉节点间的依赖关系和拓扑结构, 从而在多个领域中展现出卓越的性能, 尤其是在交通流量预测等复杂系统建模任务中, 具有广泛的应用前景.

随后, 本文对交通流量预测领域的相关研究进行了综述, 发现当前大多数研究基于 CNN-LSTM 的变体模型. 这些方法尽管在时间序列建模上取得了一定的成功, 但通常缺乏对交通网络中节点间复杂关系的学习能力, 未能充分利用图结构的信息. 交通流量数据本质上具有图结构特征, 例如路网的拓扑关系和交通流量的空间依赖性, 因此, 传统的基于 CNN 和 LSTM 的模型往往不能有效地捕捉到这些空间相关性, 从而限制了预测的准确性和泛化能力.

近年来, 注意力机制因其在处理序列数据时展现出的优良性质而受到广泛关注. 注意力机制能够自适应地为不同时间步的输入数据分配不同的权重, 从而有效捕捉长期依赖关系, 克服了传统序列模型中梯度消失或爆炸的问题. 此外, 注意力机制还

具有较好的可解释性,可以明确指示出模型在预测时关注的关键时间点和输入特征.这一特性使得其在交通流量预测任务中具有潜力,尤其是在考虑到交通流的时空动态变化时,注意力机制可以帮助模型更精确地捕捉到时间和空间的复杂依赖.

因此,本文主要使用了基于图神经网络和注意力机制相结合的预测方法.该方法不仅能够有效学习交通网络的图结构,还能够利用注意力机制自动关注时序数据中关键的时间步和空间位置,从而提高交通流量预测的精度.在图神经网络中引入注意力机制,能够更好地融合交通流量数据的时空信息,为智能交通系统的优化提供更加精确的预测结果.具体来说,采用融合了时间与空间的注意力机制,并与图卷积网络共同学习交通网络数据中的相关模式并做出预测.结合图神经网络和注意力机制的方法具有显著的优势,尤其是在交通流量预测等时空数据建模任务中,能够有效弥补传统图神经网络的局限性.首先,图神经网络主要被应用于处理截面数据,而在交通流量预测这类问题中,数据不仅包含空间结构的信息,还具有明显的时序特征.通过引入注意力机制,可以将时序信息与图结构信息结合,从而使得模型能够同时学习空间和时间的依赖关系.注意力机制能够自适应地为不同时间步的输入数据分配不同的权重,使得模型能够在多个时间步之间有效地捕捉长短期依赖.基于注意力的架构通过自注意力机制并行处理整个序列,从根本上避免了传统 RNN 的串行计算限制,从而进一步提升了训练效率和模型的表达能力.因此,使用注意力机制进行序列预测,不仅能够有效缓解梯度爆炸问题,还能够提升模型的整体性能和泛化能力.另外,图神经网络在处理图数据时,常常会遇到“过平滑”问题,即随着网络层数的增加,节点特征趋于一致,导致模型无法有效区分不同节点的特征,影响模型的表达能力.通过引入空间注意力机制,可以缓解这一问题.空间注意力机制能够动态地调整节点间信息传递的权重,从而避免节点特征过度平滑,使得每个节点能够更好地保留其特征信息,进而提高模型的预测精度.空间注意力机制通过聚焦于重要的节点及其邻域,减少了无关信息的干扰,使得模型在捕捉图结构信息的同时,能够更加精确地处理时空依赖关系.

本研究探讨了时空注意力机制-图网络模型在多信息融合方面的适应性.通过引入 POI 和天气等外源信息,增强了模型对交通流的预测能力.实验结果表明,多信息融合有助于提高预测精度,例如,在 LA 数据集中加入道路占有率后, RMSE 和 MAPE 预测结果下降.此外,不同天气状况对行车速度有显著影响,进一步验证了外源信息的价值.未来研究可继续探索有效的外源信息选择与融合方法,以优化交通流预测模型的性能.

本文还对模型中的其他关键组件进行了优化.图卷积是图神经网络的核心操作

之一,它通过对图中节点的邻域进行加权平均来更新节点特征。然而,标准的图卷积操作计算复杂度较高,尤其是在大规模图数据中,这使得模型的训练速度和推理效率受到一定的限制。为了解决这一问题,本文采用了 Chebyshev 滤波器 (Cheby-filter) 来优化图卷积的计算过程。Chebyshev 滤波器是一种近似的图滤波器,它通过多项式逼近图拉普拉斯算子,从而有效减少了传统图卷积中对全图矩阵的运算需求。具体来说, Chebyshev 滤波器能够通过低阶多项式对图拉普拉斯矩阵进行近似,从而避免了计算高次图拉普拉斯矩阵的昂贵操作,大大提高了计算效率。这一优化策略的引入,不仅能够加快图神经网络的学习速度,还能在处理大规模图数据时保持较高的精度。相比于传统的图卷积操作, Chebyshev 滤波器能够以更少的计算开销实现较为精确的图卷积,从而使得模型在学习过程中更加高效。特别是在交通流量预测等需要实时预测的应用中, Chebyshev 滤波器的使用能够有效提高模型的训练和推理速度,为实际应用提供更强的计算支持。论文的第二部分提出了一种自适应图卷积操作,由两部分组成,节点自适应参数学习为每个节点单独分配参数,通过学习一个低维的节点嵌入矩阵和一个共享权重池,使每个节点能够从权重池中提取适合自身的参数。这一方法不仅降低了计算复杂度,还能够从流量数据中自动学习特定于节点的模式,从而提升预测精度。第二部分数据自适应图生成不再依赖传统的固定邻接矩阵。通过引入自适应学习机制,模型可以动态地学习最合适的邻接矩阵,从而根据实际数据中的时空依赖关系进行优化。这一创新使得模型能够在图卷积过程中,根据不同任务需求自动调整邻接矩阵,并能够挖掘和学习节点之间的隐藏模式,从而提升模型的灵活性和表达能力。同时,由于不再需要预设的邻接矩阵,这不仅减少了计算负担,还能加速训练和推理过程,提高计算效率。

模型最终预测结果较基线模型以及部分结构退化模型均有一定提升。

5.2 展望

随着交通流量预测模型的不断发展和应用,可以从多个角度进一步拓展和提升模型的应用范围及其实际效果。

交通流量预测不仅仅局限于对交通流量的预测,还可以扩展到预测其他有实际意义的变量,例如到达时间、拥堵时间以及交通拥堵的发生概率等。通过对这些变量的预测,可以为驾驶员、交通管理者以及物流公司提供更加实用的信息,优化交通运输和货物流通效率。例如,基于精确的到达时间预测,智能导航系统可以为用户提供实时的路线规划,避免不必要的延误,提升出行体验 (李琦, 2023)。同时,预测到达时间还可以帮助物流公司提高运输效率,减少资源浪费,降低运营成本。

此外, 我们的模型虽然目前主要应用于交通领域, 但其方法和思路完全可以扩展到其他领域. 例如, 工业领域中的故障识别和诊断任务也依赖于传感器数据的时序建模. 许多工业设备通过传感器收集数据, 并将其转化为时间序列, 这些数据能够反映设备的运行状态. 当出现故障时, 传感器数据会出现特定的变化模式, 因此, 通过借鉴交通流量预测中的图神经网络和注意力机制的结合方式, 我们可以开发出用于故障检测、诊断的智能系统. 这类系统能够实时监控设备状态, 提前发现潜在问题并发出预警, 从而减少设备故障的发生, 提高生产线的稳定性和效率. 类似的, 医疗健康领域也可以通过分析医院的病人数据、设备运行状态等, 预测疾病的发生趋势、诊断疾病, 提升医疗服务质量.

另外, 随着数据规模的不断增加, 如何在大规模图中高效地进行学习, 节省计算资源和计算开销, 成为一个重要的研究方向. 在现实应用中, 尤其是智能交通系统和工业监控中, 图神经网络常常需要处理庞大的图数据, 而图神经网络的计算复杂度随图规模的增大而显著增加. 未来的研究可以重点关注如何设计高效的图学习算法, 减少计算资源的消耗. 例如, 可以采用图采样技术、图分解方法进一步提高计算效率. 此外, 分布式图学习方法和边缘计算的结合, 也为大规模图学习提供了新的思路. 在边缘计算环境下, 部分数据处理可以在接近数据源的地方完成, 从而减少对中央服务器的依赖, 降低数据传输的延迟和带宽消耗. 也可以引入生成对抗网络, 以提升模型的预测准确率和推理速度 (钟强, 2023).

在未来的研究中, 还可以探索更多图神经网络在不同场景下的应用和优化. 例如, 如何结合强化学习来进一步提升预测模型的智能化水平, 使得模型不仅能够预测交通流量, 还能进行动态的决策和优化. 在智能交通领域, 预测与决策的结合至关重要, 能够帮助交通管理系统根据实时交通流量情况调整交通信号灯、引导车辆绕行等, 以减少交通拥堵和提高通行效率. 此外, 随着无人驾驶技术的发展, 基于图神经网络和深度学习的多模态数据融合方法也将成为研究的热点, 特别是在复杂的城市交通环境中, 如何结合来自不同传感器 (如摄像头、雷达、激光雷达等) 的信息进行综合分析, 将成为智能交通系统的一个重要发展方向.

总体来说, 未来图神经网络与注意力机制的结合将在多个领域展现出巨大的潜力, 从交通流量预测到故障诊断, 再到其他基于时序数据的应用, 图神经网络将继续发挥其在时空数据建模中的优势. 同时, 随着计算资源的不断优化和新算法的提出, 图神经网络在大规模数据处理方面的挑战也将逐步得到解决, 推动相关领域实现更广泛的应用.

参考文献

- [1] 贾若, 戴昇宏, 黄霓. 交通拥堵判别方法研究综述[J]. 华南理工大学学报 (自然科学版), 2021, 49(4): 124–139.
- [2] 中国政府网. 中共中央 国务院印发《交通强国建设纲要》[EB/OL]. (2019-09-19)[2025-04-25]. https://www.gov.cn/gongbao/content/2019/content_5437132.htm.
- [3] Vlahogianni E I. Computational Intelligence and Optimization for Transportation Big Data: Challenges and Opportunities[G]. In: Lagaros N D, Papadrakakis M. Computational Methods in Applied Sciences: Engineering and Applied Sciences Optimization. Cham: Springer, 2015: 107–128.
- [4] Williams B M, Hoel L A. Modeling and forecasting vehicular traffic flow as a seasonal ARIMA process: Theoretical basis and empirical results[J]. Journal of transportation engineering, 2003, 129(6): 664–672.
- [5] Sims C A. Macroeconomics and Reality[J]. Econometrica, 1980, 48(1): 1–48.
- [6] 孙天瑀. 基于向量自回归的城市交通流量预测算法研究[D/OL]. [硕士学位论文]. 北京交通大学, 2022. DOI: 10.26944/d.cnki.gbfju.2022.002851.
- [7] Kalman R E. A New Approach to Linear Filtering and Prediction Problems[J]. Transactions of the ASME—Journal of Basic Engineering, 1960, 82(1): 35–45.
- [8] 张壕旖. 噪声免疫 CatBoost 与卡尔曼滤波短期交通流预测研究[D/OL]. [硕士学位论文]. 汕头大学, 2021. DOI: 10.27295/d.cnki.gstou.2021.000267.
- [9] 于滨, 邬珊华, 王明华, 等. K 近邻短时交通流预测模型[J]. 交通运输工程学报, 2012, 12(2): 105–111.
- [10] Jeong Y S, Byon Y J, Castro-Neto M M, et al. Supervised Weighting-Online Learning Algorithm for Short-Term Traffic Flow Prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(4): 1700–1707.
- [11] Lippi M, Bertini M, Frasconi P. Short-term traffic flow forecasting: An experimental comparison of time-series analysis and supervised learning[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(2): 871–882.

- [12] Zhang J, Zheng Y, Qi D. Deep spatio-temporal residual networks for citywide crowd flows prediction[C]. In: AAAI. 2017: 1655–1661.
- [13] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735–1780.
- [14] Wu Y, Tan H. Shortterm traffic flow forecasting with spatial-temporal correlation in a hybrid deep learning framework[J]. arXiv preprint arXiv:1612.01022, 2016.
- [15] Yao H, Wu F, Ke J, et al. Deep multi-view spatial-temporal network for taxi demand prediction[C]. In: AAAI Conference on Artificial Intelligence. 2018: 2588–2595.
- [16] Shi X, Chen Z, Wang H, et al. Convolutional lstm network: A machine learning approach for precipitation nowcasting[C]. In: NIPS. 2015: 802–810.
- [17] Yao H, Tang X, Wei H, et al. Modeling spatial-temporal dynamics for traffic prediction [J]. arXiv preprint arXiv:1803.01254, 2018.
- [18] Zhang J, Zheng Y, Qi D, et al. Predicting citywide crowd flows using deep spatio-temporal residual networks[J]. Artificial Intelligence, 2018, 259: 147–166.
- [19] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention[C]. In: International conference on machine learning. 2015: 2048–2057.
- [20] Velickovic P, Cucurull G, Casanova A, et al. Graph attention networks[C]. In: International Conference on Learning Representations. 2018.
- [21] Liang Y, Ke S, Zhang J, et al. GeoMAN: Multi-level Attention Networks for Geosensory Time Series Prediction[C]. In: International Joint Conference on Artificial Intelligence. 2018: 3428–3434.
- [22] Guo S, Lin Y, Feng N, et al. Attention Based Spatial-Temporal Graph Convolutional Networks for Traffic Flow Forecasting[C]. In: Proceedings of the AAAI Conference on Artificial Intelligence: vol. 33: 1. AAAI Press, 2019: 922–929.
- [23] Zheng C, Fan X, Wang C, et al. GMAN: A graph multi-attention network for traffic prediction[R]. Fujian Key Laboratory of Sensing, 2020.
- [24] Wu Z, Pan S, Long G, et al. Graph WaveNet for Deep Spatial-temporal Graph Modeling[J]. arXiv preprint arXiv:1906.00121, 2019.

- [25] Bai L, Yao L, Li C, et al. Adaptive Graph Convolutional Recurrent Network for Traffic Forecasting[C]. In: Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2020: 17804–17815.
- [26] Chung F R K. Spectral Graph Theory[M]. American Mathematical Society, 1997.
- [27] 刘忠雨, 李彦霖, 周洋. 深入浅出图神经网络[M]. 北京: 机械工业出版社, 2021: 92.
- [28] Defferrard M, Bresson X, Vandergheynst P. Convolutional neural networks on graphs with fast localized spectral filtering[C]. In: Advances in Neural Information Processing Systems. 2016: 3844–3852.
- [29] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.
- [30] 马耀. 图深度学习[M]. 北京: 电子工业出版社, 2021: 23.
- [31] Maehara T. Revisiting Graph Neural Networks: All We Have is Low-Pass Filters[J]. arXiv preprint arXiv:1905.09550, 2019.
- [32] Greff K, Srivastava R K, Koutník J, et al. LSTM: A search space odyssey[J]. IEEE transactions on neural networks and learning systems, 2016, 28(10): 2222–2232.
- [33] 刘建伟, 宋妍. 循环神经网络研究综述[J]. 控制与决策, 2022, 37(11): 2753–2768.
- [34] Perozzi B, Al-Rfou R, Skiena S. DeepWalk: Online Learning of Social Representations [C]. In: Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, NY, USA: ACM, 2014: 701–710.
- [35] Grover A, Leskovec J. node2vec: Scalable Feature Learning for Networks[C/OL]. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, NY, USA: ACM, 2016: 855–864. DOI: 10.1145/2939672.2939754.
- [36] Zhao L, Song Y, Zhang C, et al. T-gcn: A temporal graph convolutional network for traffic prediction[J]. IEEE transactions on intelligent transportation systems, 2019, 21(9): 3848–3858.
- [37] 胡晓荣. 基于图神经网络的路网短时交通流预测算法研究[D/OL]. [硕士学位论文]. 成都: 电子科技大学, 2023. DOI: 10.27005/d.cnki.gdzku.2023.004733.

- [38] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. In: IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770–778.
- [39] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[C]. In: Proceedings of the 3th International Conference on Learning Representations (ICLR). San Diego, CA, USA: OpenReview.net, 2015.
- [40] Han L, Du B, Sun L, et al. Dynamic and Multi-faceted Spatio-temporal Deep Learning for Traffic Speed Forecasting[C]. In: Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. New York, NY, USA: ACM, 2021: 547–555.
- [41] Wu Z, He P. Graph Wavelet Networks for Deep Learning on Graphs[C]. In: Proceedings of the 36th International Conference on Machine Learning: vol. 14: 1. 2019: 4052–4061.
- [42] Zhang J, Zheng Y, Sun J, et al. Flow prediction in spatio-temporal networks based on multitask deep learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 32(3): 468–478.
- [43] Wu Z, Pan S, Long G, et al. Graph WaveNet: A deep learning framework for traffic forecasting[C]. In: Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI). 2019: 1907–1913.
- [44] Rao X, Wang H, Zhang L, et al. FOGS: First-order gradient supervision with learning-based graph for traffic flow forecasting[C]. In: Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence (IJCAI). Vienna, Austria: Morgan Kaufmann, 2022: 3926–3932.
- [45] 李琦. 环形交叉口出口关联道路干线协调控制研究[D/OL]. [硕士学位论文]. 大连海事大学, 2023. DOI: 10.26989/d.cnki.gdlhu.2023.000847.
- [46] 钟强. 基于图卷积神经网络的交通流预测研究[D/OL]. [硕士学位论文]. 中南大学, 2023. DOI: 10.27661/d.cnki.gzhnu.2023.002004.

致 谢

在 *** 读书的六年时光，转瞬即逝。在我的脑海中，忽然又想起荟 9 楼下樱花大道上的樱花，在清明后一场大雨中满地飘零；又或是某天早起，晨光透过桂中路两边高大的梧桐树，洒下一地的斑驳。

感谢导师 *** 教授的指导。论文从准备阶段、选题、写作，他提供了很多实际建议，也感谢 *** 这两年来在学习上的帮助。祝愿身体健康，天天开心。

感谢父母，生我养我。无条件支持我一切决定，愿身体健康，天天开心。

感谢这六年陪伴过我的朋友们。在 ***，又或者是在北京、上海的实习途中，有太多次袒露脆弱且一击就碎的时刻，感谢有你们一直为我准备的肩膀。

感谢 *** 两年的收留，在 *** 被市井煮沸，可回到桂子山总能找到内心的最后一抹宁静。爱在 ***，后会有期。

2025 年 5 月 17 日